Patrones multivariados del tráfico de red y detección de ataques en UNSW-NB15

Proyecto integrador

[Integrante 1]
[Integrante 2]
[Integrante 3]
[Integrante 4]

Universidad Católica de Córdoba
Facultad de [completar]
Carrera de [completar]
Sede Río Cuarto

Materia: Estadística Multivariada
Docente a cargo: Prof. Silvana Malpassi

Fecha de entrega: [día] de [mes] de 2026

Índice

1. Introducción **4**

2. Datos **4**

3. Análisis de componentes principales **5**

4. Análisis factorial **7**

5. Análisis de conglomerados **9**

6. Análisis de correspondencias simple y múltiples **11**
6.1. Construcción de X_cat 11
6.2. Análisis de correspondencias simple: `tipo_trafico` × `state_g` 11
6.3. Análisis de correspondencias múltiples 11

7. Regresión logística **13**

8. Integración y conclusiones **14**

Referencias bibliográficas **15**

A. Figuras y tablas complementarias **16**
A.1. Datos 16
A.2. Análisis factorial 16
A.3. Análisis de conglomerados 21
A.4. Análisis de correspondencias 21
A.5. Regresión logística 21
A.6. Integración de las técnicas 21

B. Código fuente **25**
B.1. Scripts de R 25
`R/00_datos.R` 25
`R/01_acp.R` 27
`R/02_af.R` 28
`R/aux_diagnostico_af.R` 29
`R/03_cluster.R` 31
`R/04_acm.R` 32
`R/05_integracion.R` 33
`R/06_logistica.R` 34
`R/ejecutar_todo.R` 38
B.2. Scripts de Python 38
`python/graficos_etapa0.py` 38
`python/graficos_parte2.py` 40
`python/graficos_logistica.py` 44
`python/verificar_resultados.py` 46

Índice de figuras

1. Correlaciones entre las 12 variables de X_num . . . 6
2. Codo y biplot del ACP . . . 7
3. Codo y silhouette para elegir k . . . 9
4. Perfiles por cluster y dendrograma de variables . . . 10
5. Mapa del análisis de correspondencias simple . . . 11
6. Mapa de categorías del ACM . . . 12
A.1. Diagramas de caja de X_num . . . 17
A.2. Histogramas en escala logarítmica . . . 18
A.3. Histogramas en escala original . . . 19
A.4. Frecuencias de las variables de X_cat . . . 20
A.5. MSA por variable y KMO global . . . 20
A.6. Análisis paralelo del AF . . . 21
A.7. Dendrograma Ward.D2 de los flujos . . . 21
A.8. Inercia del ACM: autovalores y porcentaje ajustado . . . 21
A.9. Clusters suplementarios y eta^2 del ACM . . . 22
A.10. Curva ROC y matriz de confusión de M2 . . . 23
A.11. Odds ratios y calibración de M2 . . . 23

Índice de tablas

1. Variables de X_num y bloque esperado . . . 5
2. Cargas y calidad de representación del ACP . . . 6
3. Matriz de patrón, comunalidades y unicidades del AF . . . 8
4. Comparación entre ACP y AF . . . 8
5. Perfil de los seis clusters . . . 9
6. Variables y categorías de X_cat . . . 11
7. Odds ratios del modelo M2 . . . 13
A.1. Controles de calidad de la muestra . . . 16
A.2. Atípicos de Tukey por variable . . . 16
A.3. Diagnóstico de soluciones factoriales . . . 16
A.4. Autovalores observados y simulados . . . 17
A.5. Cruce Ward y k-means . . . 17
A.6. Cruce k-means original y sobre puntajes del ACP . . . 18
A.7. Cruce entre clusters y tipo de tráfico . . . 18
A.8. Contribuciones y cos2 de las categorías del ACM . . . 22
A.9. Eta^2 de cada variable del ACM . . . 22
A.10. Perfiles fila del ACS . . . 22
A.11. Integración de las técnicas . . . 24

1. Introducción

La detección de intrusiones busca identificar, a partir del tráfico que circula por una red, las conexiones que forman parte de un ataque. Para estudiar este problema se usan bases etiquetadas; una de las más difundidas es UNSW-NB15, creada por Moustafa and Slay (2015) en el laboratorio de ciberseguridad de UNSW Canberra, que combina tráfico normal con nueve tipos de ataque generados de forma sintética (Moustafa and Slay, 2016). Cada fila es un flujo, una conversación entre un origen y un destino, descrita por variables de volumen, tiempo, conexión y contexto. Reúne muchas variables numéricas correlacionadas, varias categóricas y una etiqueta externa (normal o ataque) con la cual contrastar, sin usarla para construirlos, los patrones que las técnicas encuentren.

Nuestra pregunta guía es: *¿qué patrones de volumen, temporización y repetición de conexiones caracterizan a los flujos de red de UNSW-NB15, y en qué medida esos patrones, junto con el protocolo, el servicio y el estado de la conexión, distinguen el tráfico normal del de ataque al punto de permitir estimar la probabilidad de que un flujo sea un ataque?* Las hipótesis se apoyan en el diseño de la base y en el dominio; como ya habíamos explorado los datos al fijarlas, son de partida y las contrastamos al final, incluidas las que no se cumplan.

- **H1.** Las 12 variables numéricas forman tres bloques correlacionados entre sí: volumen, temporización y repetición de conexiones; el ACP, el AF y el cluster de variables deberían recuperarlos.
- **H2.** Existen grupos de flujos definidos sobre todo por la forma de la conexión; separan parcialmente lo normal de lo atacante, pero no los tipos de ataque entre sí.
- **H3.** El ataque se asocia con conexiones incompletas (estado INT) y sin respuesta del destino; lo normal, con conexiones cerradas (FIN, CON) y servicios identificados.
- **H4.** Un modelo logístico con los ejes del ACP, el protocolo, el servicio y el estado alcanza un AUC mayor a 0,80 en datos de validación.

El informe sigue el orden del análisis: datos (sección 2), componentes principales y factores (3 y 4), conglomerados (5), correspondencias (6), regresión logística (7) e integración, con el contraste de H1–H4 y las conclusiones (8).

2. Datos

Origen y muestra. Trabajamos con UNSW-NB15 (Moustafa and Slay, 2015, 2016), de uso académico citando a sus autores, con R (R Core Team, 2024) y los paquetes `psych` y `ca`. El tráfico normal es realista, pero los ataques son sintéticos. En las variables, `s` indica el origen y `d` el destino. Del archivo de entrenamiento (175.341 flujos) tomamos 5.000 flujos únicos, con muestreo estratificado proporcional por `attack_cat`: 48,2 % normales y 51,8 % ataques (Exploits 18,4 %, Fuzzers 15,0 %, Reconnaissance 7,0 %, otros 11,5 %). Sin duplicados (eran el 38,6 % del original, casi todos ataques automáticos), las proporciones no son prevalencias reales de una red.

Transformación. Las variables son positivas, muy asimétricas y de rangos muy amplios. Aplicamos $\log(x+1)$, que conserva los ceros y baja la asimetría de `sbytes` de 33,3 a 1,0 (Anexo A, Figuras A.3 y A.2).

Variables. X_num son las 12 variables de la Tabla 1, en escala logarítmica. X_cat tiene siete variables: `tipo_trafico`, `proto_g`, `service_g` y `state_g` (con categorías agrupadas) y tres numéricas discretizadas, `respuesta_destino`, `duracion_banda` y `bytes_origen_banda`, cuyos cortes se justifican en la sección 6; ninguna categoría baja del 5 % (Anexo A, Figura A.4). `tipo_trafico`, `attack_cat` y `label` no construyen componentes, factores ni clusters: solo colorean o se cruzan después.

Tabla 1. Variables de X_num (todas en escala $\log(x+1)$; la unidad es la de la variable original).

Variable	Bloque esperado	Significado	Unidad
`spkts`	Volumen	Paquetes enviados por el origen	paquetes
`sbytes`	Volumen	Bytes enviados por el origen	bytes
`dbytes`	Volumen	Bytes enviados por el destino	bytes
`dur`	Temporización	Duración total del flujo	segundos
`sinpkt`	Temporización	Tiempo entre paquetes del origen	ms
`sjit`	Temporización	Jitter del origen (variación de esos tiempos)	ms
`synack`	Temporización	Tiempo SYN a SYN-ACK (0 si no es TCP)	segundos
`ct_srv_src`	Repetición	Últimas 100 conexiones, igual servicio y origen	conexiones
`ct_srv_dst`	Repetición	Ídem con igual servicio y destino	conexiones
`ct_src_ltm`	Repetición	Ídem con igual origen	conexiones
`ct_src_dport_ltm`	Repetición	Ídem con igual origen y puerto destino	conexiones
`ct_dst_sport_ltm`	Repetición	Ídem con igual destino y puerto origen	conexiones

Calidad. No hay faltantes, duplicados ni valores imposibles; la única incidencia es un flujo con `is_ftp_login` = 4 (código no binario), que conservamos porque esa variable no se usa (Anexo A, Tabla A.1). No imputamos los ceros estructurales: `synack` 29,6 %, `sjit` 25,9 % y `dbytes` 18,9 % (sin respuesta). Para los atípicos usamos el criterio de Tukey ($1{,}5\times$ RIC) sobre la escala logarítmica: 1.715 flujos (34,3 %) tienen al menos una de las 12 variables fuera de los límites, sobre todo `log_dbytes` (21,1 %, de los cuales 945 son esos ceros; Anexo A, Tabla A.2 y Figura A.1). Los conservamos todos: en ciberseguridad lo extremo puede ser el fenómeno de interés.

Descriptiva y supuestos. La Figura 1 muestra tres zonas: volumen (`spkts`–`sbytes` 0,86), temporización (`sinpkt`–`sjit` 0,85) y repetición (`ct_srv_src`–`ct_srv_dst` 0,85), esta última con correlaciones negativas con el resto ($-0,13$ a $-0,43$). `sjit` también se asocia con el volumen (0,46 a 0,55), así que los bloques no están aislados.

Los supuestos se cumplen (Anexo A, Figura A.5): determinante $6{,}3 \times 10^{-5}$ (mayor que 10^{-5}), KMO global 0,748 (Kaiser, 1974), MSA mínima 0,621 (`log_spkts`) y Bartlett significativo (χ^2 = 48.303,5; 66 gl; p <0,001). Con 14 candidatas el determinante era $1{,}0 \times 10^{-7}$ por la redundancia de `dpkts` (r = 0,95 con `dbytes`) y de `rate` (r = $-0,91$ con `sinpkt`); quitar solo `dpkts` no bastaba ($5{,}2 \times 10^{-6}$), por lo que excluimos ambas.

Vínculo con H1. Las correlaciones son compatibles con tres bloques, con separación parcial entre volumen y temporización; los capítulos siguientes ponen a prueba si los métodos los recuperan.

3. Análisis de componentes principales

Estandarización. Aplicamos `prcomp(X_num, scale. = TRUE)`. Las varianzas de las variables logarítmicas van de 0,002 (`log_synack`) a 13,61 (`log_sjit`), más de 7.500 veces, y

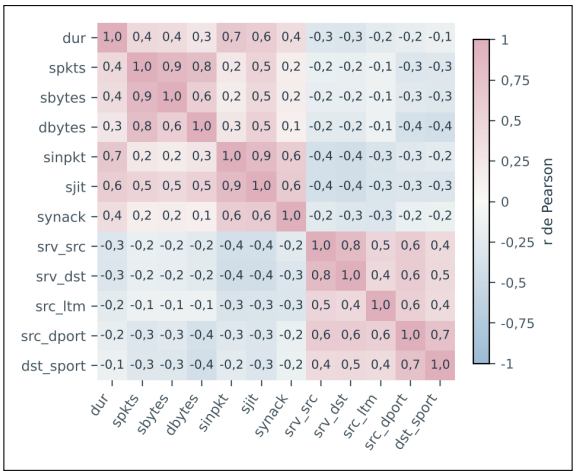


Figura 1. Correlaciones de Pearson entre las 12 variables de X_num. Se distinguen tres bloques; el de repetición se asocia de forma negativa con los otros dos. Fuente: elaboración propia con UNSW-NB15.

tres de ellas (`log_sjit`, `log_dbytes` y `log_sinpkt`) reúnen el 83,2 % de la varianza total. Sin estandarizar, la primera componente captaría el 66,4 % de la variabilidad (43,3 % con estandarización): reflejaría las escalas y no las relaciones entre variables. Por eso usamos la matriz de correlaciones (Johnson and Wichern, 2007).

Cantidad de componentes. Los autovalores son 5,195, 2,026 y 1,721 para las tres primeras componentes y el cuarto cae a 0,759: solo tres superan 1 (Kaiser). El codo (Figura 2, izquierda) cae hasta la tercera y luego se aplana. Las tres explican el 43,3 %, el 16,9 % y el 14,3 % de la varianza (74,5 % acumulado) y cada una de las restantes menos del 6,4 %. Retenemos tres: son interpretables y coinciden con los bloques de H1.

Interpretación. Según la Tabla 2, en CP1 las siete variables de volumen y temporización tienen signo positivo (0,54 a 0,82) y las cinco de repetición, negativo ($-0,56$ a $-0,70$); aportan más `log_sjit` (13,1 %) y `log_sinpkt` (9,9 %). CP2 se construye con `log_spkts` (20,1 %), `log_sbytes` (15,7 %) y las repeticiones `log_ct_srv_src` y `log_ct_srv_dst` (12,7 % y 11,8 %), todas en positivo. CP3, con `log_sinpkt` (20,1 %) y `log_synack` (19,6 %), en sentido opuesto a bytes y paquetes.

Tabla 2. Correlaciones entre cada variable y las tres componentes retenidas, en negrita las de $|r| \geq 0{,}5$, y calidad de representación acumulada (suma de cos2 en CP1–CP3).

Variable	Bloque esperado	CP1	CP2	CP3	cos2 total
`log_spkts`	Volumen	**0,64**	**0,64**	−0,35	0,94
`log_sbytes`	Volumen	**0,60**	**0,56**	−0,32	0,78
`log_dbytes`	Volumen	**0,64**	0,45	−0,39	0,76
`log_dur`	Temporización	**0,64**	0,27	0,40	0,64
`log_sinpkt`	Temporización	**0,72**	0,03	**0,59**	0,86
`log_sjit`	Temporización	**0,82**	0,23	0,36	0,87
`log_synack`	Temporización	**0,54**	0,00	**0,58**	0,63
`log_ct_srv_src`	Repetición	**−0,68**	**0,51**	0,08	0,73
`log_ct_srv_dst`	Repetición	**−0,70**	0,49	0,04	0,73
`log_ct_src_ltm`	Repetición	**−0,56**	0,45	0,00	0,52
`log_ct_src_dport_ltm`	Repetición	**−0,69**	0,43	0,41	0,82
`log_ct_dst_sport_ltm`	Repetición	**−0,61**	0,29	0,44	0,65

Nombre de las componentes. CP1 opone el tamaño y el ritmo del flujo (más paquetes,

bytes, duración, espaciado y jitter) a la repetición de conexiones: *magnitud del flujo frente a repetición*. CP2 reúne volumen y repetición en positivo; la llamamos *volumen de tráfico*, aunque no es un eje puro, porque las repeticiones también cargan sobre ella (0,29 a 0,51). CP3 queda definida por el espaciado entre paquetes y el tiempo del handshake: *ritmo lento*.

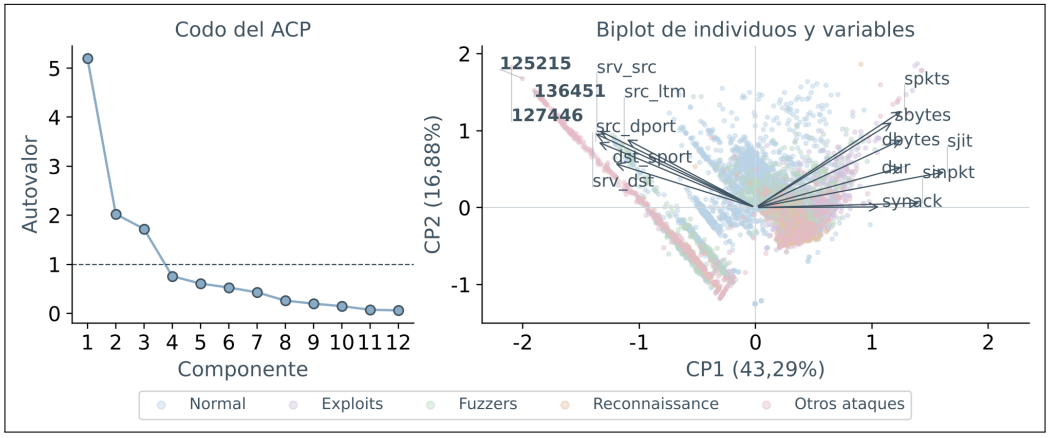


Figura 2. Gráfico del codo (izquierda) y biplot de CP1 y CP2 (derecha), con los flujos coloreados por `tipo_trafico`. Los tipos de tráfico se solapan en gran medida; los tres flujos extremos están rotulados con su identificador. Fuente: elaboración propia con UNSW-NB15.

Observaciones extremas. Medimos la distancia de cada flujo al centro en las tres componentes, ponderada por la varianza de cada una. Los tres más alejados (id 127446, 125215 y 136451; distancias 43,6, 38,0 y 32,6) tienen el mismo perfil: tráfico UDP al servicio DNS en estado INT, de 2 paquetes y 114 bytes, sin respuesta y de 6 a 9 microsegundos; son del tipo "otros ataques" (Generic). Lo extremo es la repetición: `ct_srv_src` va de 45 a 50 (mediana 3) y `ct_src_ltm` de 33 a 50 (mediana 2), de ahí su puntaje muy negativo en CP1 ($-8,7$ a $-9,6$). No son errores: 152 flujos comparten ese patrón (DNS, INT, sin respuesta) y todos son ataques; es un grupo distinto del cluster 3 de la sección 5 (147 flujos), que se define con las 12 variables. En el biplot, el tipo de tráfico no separa grupos nítidos.

Vínculo con H1. El ACP pide tres componentes, como bloques se esperaban, y aísla el de repetición, opuesto al resto en CP1. Volumen y temporización, en cambio, no se separan en CP1 (ambos positivos) y `log_sjit` carga más en CP1 que en CP3. H1 se sostiene en parte; la rotación del análisis factorial mostrará si los tres bloques emergen con más claridad.

4. Análisis factorial

Los supuestos se cumplen (sección 2: KMO 0,748, MSA mínimo 0,621, Bartlett y determinante), por lo que no se eliminó ninguna variable. El análisis paralelo (Horn, 1965) sugiere cuatro factores, pero el cuarto autovalor observado es 0,127 (simulado: 0,036) y supera al azar sobre todo porque con $n = 5.000$ se detecta casi cualquier estructura; los tres primeros quedan muy por encima (Anexo A, Figura A.6). El criterio de Kaiser sobre la matriz reducida da 4,93; 1,78; 1,44 y 0,43: tres factores, y el cuarto aporta solo 4,8 % de la varianza común. Con cuatro, además, el bloque de repetición se parte en dos factores que correlacionan 0,62 (oblimin), síntoma de sobreextracción. Retenemos **tres factores**, igual que el ACP.

Caso Heywood y estimador. Con cuatro factores `log_spkts` alcanza una comunalidad de 1,029 (minres); con tres, también (minres 1,025; ejes principales 1,095; máxima verosimilitud

0,995), con cualquier rotación. La causa es que `log_spkts` se reproduce casi por completo con el factor Volumen ($r = 0{,}86$ con `log_sbytes`), que tiene solo tres indicadores. La única combinación sin solución impropia es **tres factores con GLS** (comunalidad máxima 0,897; Anexo A, Tabla A.3), que además no obliga a quitar una variable de X_num. Usamos GLS con rotación varimax; la comunalidad de 0,87 de `log_spkts` debe leerse como "casi toda su varianza es Volumen".

Interpretación. Según la Tabla 3, cada variable carga en un único factor (mínimo 0,54) y la menor diferencia con la segunda carga es 0,29 (`log_ct_src_ltm`), por encima de 0,20: no hay cargas cruzadas ambiguas. Nombramos **F1 Repetición de conexiones**, **F2 Temporización** y **F3 Volumen**, que coinciden con los bloques de H1 y explican 68,6 % de la varianza total. Guardamos los puntajes factoriales (`af_puntajes.csv`); son estimaciones, no valores medidos.

Tabla 3. Matriz de patrón del AF (GLS, varimax; cargas $< 0{,}40$ ocultas con "–"), comunalidades (h^2) y unicidades (u^2). Fuente: elaboración propia con UNSW-NB15.

Variable	F1 Repetición	F2 Temporización	F3 Volumen	h^2	u^2
`log_ct_src_dport_ltm`	0,91	–	–	0,90	0,10
`log_ct_srv_src`	0,77	–	–	0,68	0,32
`log_ct_srv_dst`	0,76	–	–	0,69	0,31
`log_ct_dst_sport_ltm`	0,70	–	–	0,59	0,41
`log_ct_src_ltm`	0,54	–	–	0,36	0,64
`log_sinpkt`	–	0,87	–	0,83	0,17
`log_sjit`	–	0,81	–	0,87	0,13
`log_synack`	–	0,70	–	0,51	0,49
`log_dur`	–	0,68	–	0,56	0,44
`log_spkts`	–	–	0,91	0,87	0,13
`log_sbytes`	–	–	0,81	0,70	0,30
`log_dbytes`	–	–	0,79	0,70	0,30
% de la varianza total	25,1	22,4	21,1	Total 68,6	

Ajuste global. Es flojo: RMSR 0,051, TLI 0,609 y RMSEA 0,239, y el ajuste exacto se rechaza ($\chi^2 = 9.452$, 33 g.l., $p < 0{,}001$, esperable con $n = 5.000$). Con cuatro factores mejora (RMSR 0,033; TLI 0,79) pero con solución impropia: es el costo de la parsimonia. Usamos el AF de forma descriptiva y no confirmatoria (Hair et al., 2019; Revelle, 2024).

Tabla 4. Comparación entre el ACP (Etapa 1) y el AF (Etapa 2) sobre las mismas 12 variables. Fuente: elaboración propia con UNSW-NB15.

	ACP	AF (GLS, varimax)
Varianza que usa	Total (diagonal de R igual a 1)	Solo la común (la unicidad se separa)
Retenido	3 componentes, 74,5 % de la varianza total	3 factores, 68,6 % de la varianza total
Qué representan los ejes	Combinaciones lineales que resumen la varianza; ejes mixtos	Causas latentes de las correlaciones; bloques
Variables en cada eje	CP1: temporización y volumen (+0,54 a +0,82) frente a repetición ($-0{,}56$ a $-0{,}70$); CP2: volumen (+0,45 a +0,64) junto con repetición (+0,29 a +0,51); CP3: `sinpkt`, `synack` y `ct_*_port` (+0,41 a +0,59) frente a volumen ($-0{,}32$ a $-0{,}39$)	F1: las cinco `ct_*`; F2: `dur`, `sinpkt`, `sjit`, `synack`; F3: `spkts`, `sbytes`, `dbytes`

ACP versus AF. La Tabla 4 compara ambas técnicas. Para esta base y esta pregunta (qué bloques de variables se mueven juntos, H1) resulta más adecuado el **AF**: sus tres ejes son los tres bloques esperados, mientras que en el ACP cada componente combina tiempo, volumen y repetición y obliga a leer contrastes. El ACP conviene para resumir (74,5 % frente a 68,6 %), con puntajes exactos y sin soluciones impropias, por lo que lo usamos como predictor en la regresión logística. La ventaja del AF es de interpretación, no de ajuste. Respecto de H1, el AF recupera los tres bloques con cargas $\geq 0{,}54$ y coincide exactamente con el cluster de variables (Sección 5).

5. Análisis de conglomerados

Agrupamos los 5.000 flujos con las 12 variables de X_num estandarizadas, con distancia euclidiana y Ward.D2 (dendrograma en el Anexo A, Figura A.7), y comparamos con k-means (`nstart` = 25, semilla 42). Para elegir k usamos el codo y el silhouette promedio de k = 2 a 8 (Figura 3).

Tabla 5. Perfil de los seis clusters (k-means, k = 6): tamaño, porcentaje de ataques y rasgos. Fuente: elaboración propia con UNSW-NB15.

Cluster	n (%)	% ataque	Rasgos distintivos (promedios originales)
1 Transferencias voluminosas de respuesta rápida	898 (18,0)	1,4	Muchos paquetes (54) y bytes de respuesta (48.466); intervalos cortos
2 Sesiones largas y pesadas	405 (8,1)	72,6	Duración 10,4 s; 183.786 bytes enviados; poca repetición
3 Ráfagas repetidas sin respuesta	147 (2,9)	100	2 paquetes y 0 bytes de respuesta; duración casi nula; `ct_dst_sport_ltm` = 12,0 ($+5{,}1$ desvíos)
4 Conexiones medianas de ritmo lento	2.131 (42,6)	71,0	Duración 1,03 s; 11,9 paquetes; `sinpkt` 729 ms; `sjit`, `synack` altos
5 Intercambios mínimos	1.135 (22,7)	46,3	Duración 0,006 s; 2,4 paquetes; volumen bajo; repetición promedio
6 Repetición moderada de bajo volumen	284 (5,7)	34,9	`ct_srv_*` $\approx$ 17; `ct_src_dport_ltm` 5,9 ($+2{,}0$ desvíos); volumen bajo

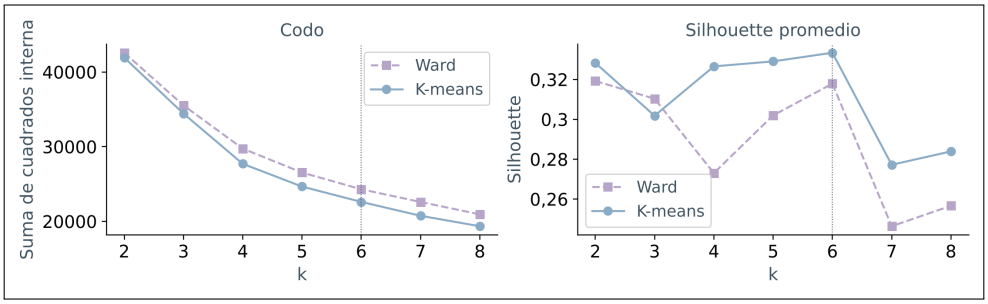


Figura 3. Codo (izquierda) y silhouette promedio (derecha) para k = 2 a 8, con Ward y k-means. El silhouette de k-means es máximo en k = 6 (0,333), casi igual a k = 2, 4 y 5, y cae en k = 7. Fuente: elaboración propia con UNSW-NB15.

La elección de k = 6 es defendible pero no contundente. El silhouette de k-means es 0,328 (k = 2), 0,302 (3), 0,327 (4), 0,329 (5), 0,333 (6), 0,277 (7) y 0,284 (8): k = 2, 4, 5 y 6 son un empate práctico (entre 0,327 y 0,333; diferencias menores que 0,007), k = 3 queda

más abajo y todos están por debajo de 0,5, lo que indica una estructura débil (Kaufman and Rousseeuw, 1990); lo claro es la caída en k = 7. El codo más marcado está en k = 4 (la suma de cuadrados baja 7.496, 6.722, 3.046, 2.054 y 1.858 al pasar de 2 a 3, . . . , 6 a 7). Elegimos k = 6 por el silhouette máximo y porque aparece un grupo pequeño y muy definido que k = 4 perdería; k = 4 también era razonable. Los clusters 2 y 6 están mal separados: su silhouette medio es 0,063 y 0,119, con 35,6 % y 26,8 % de flujos de silhouette negativo.

Jerárquico, k-means y preprocesamiento. Ward con seis grupos y k-means coinciden bastante (ARI = 0,813; Anexo A, Tabla A.5); perfilamos k-means. Sobre los puntajes de las tres componentes el ARI baja a 0,708 (0,605 con Ward; Anexo A, Tabla A.6): los grupos cambian, aunque el de 147 flujos queda íntegro. Es esperable: las componentes descartan 25,5 % de la varianza y, sin reescalar, la primera pesa más en la distancia y desplaza las fronteras entre grupos vecinos.

Cluster de variables. Ward sobre las columnas estandarizadas (Figura 4, derecha) separa tres bloques: temporización, volumen y repetición de conexiones (las cinco `ct_*`). Coincide exactamente con los tres factores del AF (ARI = 1,000) y con H1, mientras que las componentes del ACP mezclan bloques en cada eje.

Perfiles. La Figura 4 (izquierda) muestra las medias estandarizadas y la Tabla 5 los nombres, tamaños y rasgos en unidades originales; el cruce con `tipo_trafico`, solo descriptivo, está en el Anexo A, Tabla A.7.

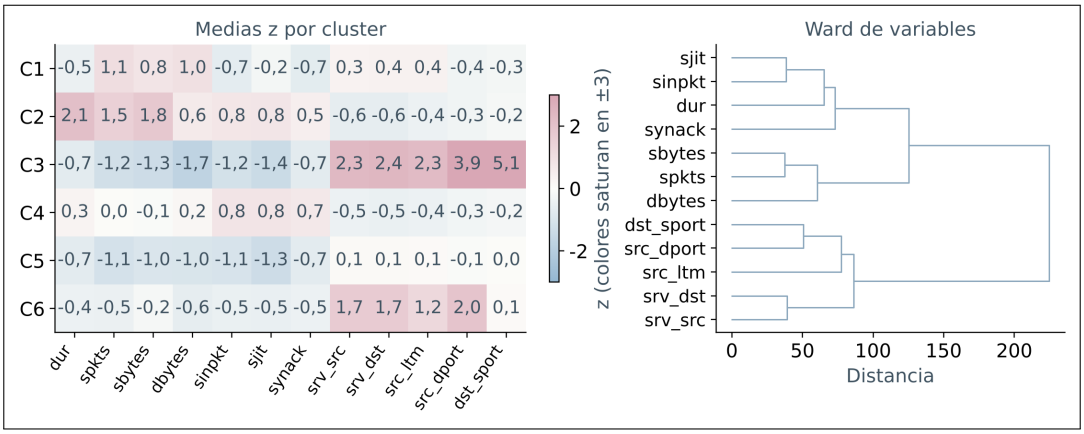


Figura 4. Izquierda: medias estandarizadas de cada variable por cluster de k-means (rojo: por encima del promedio; azul: por debajo). Derecha: dendrograma Ward de las 12 variables, que separa tres bloques. Fuente: elaboración propia con UNSW-NB15.

Hipotetizamos (sin poder contrastarlo) que el cluster 1 es transferencia legítima de datos; el 3, ráfagas automáticas de paquetes pequeños sin respuesta (130 de sus 147 flujos son Generic); el 5, consultas breves, y el 6, conexiones repetidas hacia un mismo servicio. Los clusters se guardaron en la base para el ACM.

Vínculo con H2. H2 se cumple en parte. Un cluster es casi puramente normal (el 1, 98,6 %) y otro íntegramente de ataques (el 3), definidos por la forma de la conexión; los otros cuatro mezclan ambos (34,9 a 72,6 % de ataques). Además, la parte de H2 sobre los tipos de ataque no se sostiene del todo: el cluster 3 aísla casi solo ataques Generic. Dada la silhouette baja, leemos los grupos como descripción útil y no como categorías naturales.

6. Análisis de correspondencias simple y múltiples

6.1. Construcción de X_cat

X_cat reúne siete variables (Tabla 6): cuatro categóricas existentes y tres discretizadas. Todas las categorías superan el 5 % (la menor, 6,98 %), por lo que no fusionamos ninguna. Para `dur` y `sbytes` usamos terciles (0,0185 s y 0,709 s; 564 y 1.580 bytes): ambas son muy asimétricas (`sbytes`: mediana 918 y media 16.918 bytes), y cortes de igual amplitud dejarían casi todos los flujos en una categoría; los terciles dan 33 % por categoría y no usan la etiqueta. `respuesta_destino` separa los flujos con `dpkts` = 0 ("sin respuesta"), un corte natural.

Tabla 6. X_cat: variables y categorías finales (% de 5.000 flujos). Fuente: elaboración propia con UNSW-NB15.

Variable	Categorías (%)
`tipo_trafico`	Normal 48,2 · Exploits 18,4 · Fuzzers 15,0 · Otros ataques 11,5 · Reconnaissance 7,0
`proto_g`	tcp 70,8 · udp 21,9 · otros 7,3
`service_g`	ninguno 60,0 · http 17,4 · otros 12,3 · dns 10,3
`state_g`	FIN 69,3 · INT 18,3 · CON_otros 12,4
`respuesta_destino`	con_respuesta 81,1 · sin_respuesta 18,9
`duracion_banda`	corta 33,3 · media 33,3 · larga 33,3
`bytes_origen_banda`	bajos 33,8 · medios 33,6 · altos 32,6

6.2. Análisis de correspondencias simple: `tipo_trafico` × `state_g`

Elegimos `state_g` por encarnar H3 y ser la más asociada al tipo de tráfico (V de Cramér 0,405, frente a 0,320 de `service_g` y 0,302 de `proto_g`). La asociación es significativa ($\chi^2 = 1.637{,}2$, 8 gl, $p < 0{,}001$; frecuencia esperada mínima 43,3) y dos dimensiones recogen el 100 % de la inercia (77,9 % y 22,1 %). La Dim 1 opone INT ($-1{,}009$) a CON_otros ($+0{,}662$): INT concentra el 62,3 % de Otros ataques, el 33,0 % de Fuzzers y el 26,1 % de Reconnaissance contra el 5,9 % de Normal, y CON_otros reúne al 24,0 % de Normal y a no más del 3,8 % de cada ataque. Exploits no sigue el patrón (90,4 % en FIN; Normal, 70,0 %).

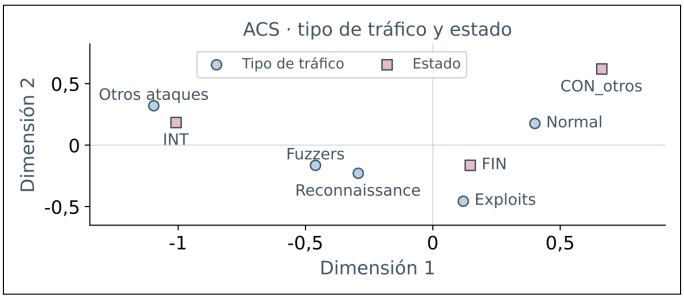


Figura 5. ACS de tipo de tráfico y estado (100 % de la inercia). Otros ataques queda junto a INT, Normal hacia CON_otros y Exploits cerca de FIN. Fuente: elaboración propia con UNSW-NB15.

6.3. Análisis de correspondencias múltiples

Con $Q = 7$ y $J = 23$, la inercia total cruda es $J/Q - 1 = 2{,}286$ y el autovalor medio $1/Q = 0{,}143$ (seis lo superan: criterio poco exigente). Los porcentajes crudos son bajos (Dim 1: 27,4 %, autovalor 0,627; Dim 2: 14,0 %, 0,321; acumulado 41,4 %). `mjca` del paquete `ca` usa por defecto `lambda = "adjusted"`, la corrección de Greenacre (Greenacre, 2017), que reportamos: inercia total ajustada 0,414, Dim 1 = 77,0 %, Dim 2 = 10,4 %, Dim 3 = 1,8 %; el

plano suma 87,4 % de inercia ajustada, cifra optimista que debe leerse junto con el 41,4 % crudo. Retenemos **dos dimensiones**: el codo se marca tras la Dim 2 (Anexo A, Figura A.8) y la tercera aporta menos del 2 % ajustado. Coordenadas y contribuciones salen de `FactoMineR::MCA` (Husson et al., 2017).

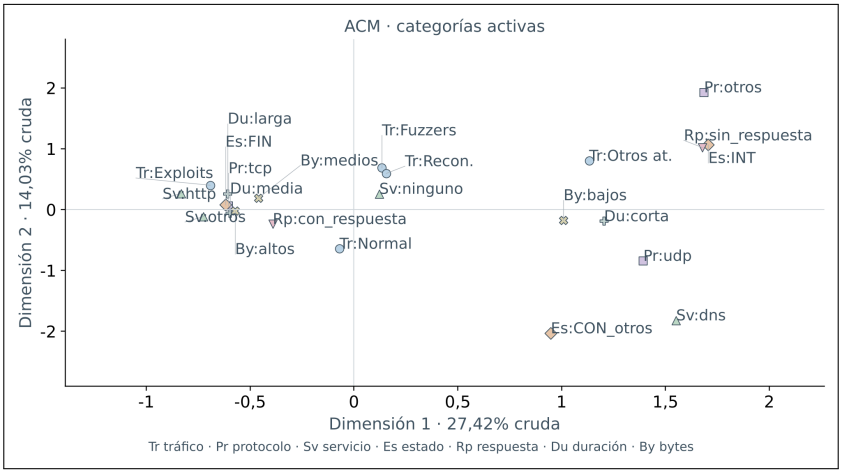


Figura 6. Mapa de categorías del ACM (Dim 1 y Dim 2, porcentajes crudos). A la derecha, flujos breves, sin respuesta y no TCP; a la izquierda, TCP, FIN, mayor duración y volumen. Fuente: elaboración propia con UNSW-NB15.

Dim 1: "conexión efímera sin respuesta" frente a "sesión TCP completa". Aportan INT (12,1 %), sin_respuesta (12,1 %), duración corta (11,0 %), UDP (9,7 %) y bytes bajos (7,8 %) contra FIN (6,1 %) y TCP (5,9 %); TCP (cos2 0,886) y FIN (0,866) son las mejor representadas. Discriminan `state_g` ($\eta^2 = 0{,}909$), `proto_g` (0,891) y `duracion_banda` (0,726); `tipo_trafico` apenas (0,242).

Dim 2: "DNS/UDP con estado CON" frente a "protocolo *otros* no establecido". Aportan CON_otros (22,8 %, cos2 0,585), dns (15,2 %) y proto *otros* (12,0 %) y Normal queda del lado DNS/CON (cos2 0,384); los demás tipos tienen cos2 de 0,03 a 0,08 y su posición es solo indicativa. Detalle en el Anexo A (Tablas A.8 y A.9). **Redundancia:** `proto_g` = *otros* implica `service_g` = ninguno (363 de 363) y casi siempre INT (344 de 363); FIN solo ocurre en TCP; y todo flujo INT es sin_respuesta (913 de 913), mientras que casi todo flujo sin respuesta es INT (913 de 945). Por eso se agrupan en el mapa.

Clusters suplementarios (Anexo A, Figura A.9). No ocupan zonas totalmente distintas: los clusters 1 (transferencias voluminosas), 2 (sesiones largas y pesadas) y 4 (conexiones medianas de ritmo lento) se superponen en la zona TCP/FIN (Dim 1 entre $-0{,}62$ y $-0{,}55$) y se distinguen por duración y bytes. El cluster 3 (ráfagas repetidas sin respuesta; Dim 1 = 2,16) queda aislado a la derecha: 100 % INT, sin respuesta, duración corta y bytes bajos, y 87,8 % UDP y dns. El cluster 5 (intercambios mínimos; Dim 1 = 1,37) es breve (96,1 % corta), UDP (73,9 %) y con 45,6 % CON_otros; el 6 (repetición moderada de bajo volumen) es intermedio. Los cos2 de los clusters en el plano son bajos salvo el 5 (0,59): lectura parcial.

Tres asociaciones. (i) *Otros ataques con INT, sin respuesta y flujos pequeños*: 62,3 % INT y 63,2 % sin respuesta (Normal: 5,9 % y 6,9 %), 62,8 % con bytes bajos. (ii) *Normal con CON_otros y con respuesta* (24,0 % y 93,1 %); el DNS no es exclusivo de lo normal (14,4 % frente a 27,6 % de Otros ataques). (iii) *Exploits con TCP/FIN, duración larga y http*: 54,7 %

larga (Normal: 23,7 %) y 44,2 % http (Normal: 9,9 %). Son frecuencias de laboratorio y el ACM es descriptivo.

Sobre H3. Se confirma en parte: INT y la falta de respuesta se asocian con ataques, pero solo con Otros ataques, Fuzzers y Reconnaissance (Exploits son casi todos FIN y con respuesta), y FIN, http y dns no caracterizan solo a lo normal.

7. Regresión logística

Diseño. Modelamos la probabilidad de que un flujo sea ataque (`label` = 1) con regresión logística (Hosmer et al., 2013) para contrastar H4. Partimos la muestra 70/30 en 3.501 flujos de entrenamiento y 1.499 de prueba (51,8 % ataques en ambos), estratificando por `attack_cat` (semilla 42; partición en `muestra_particion_70_30.xlsx`); no usamos el testing set original porque no está en el repositorio. Reajustamos el ACP solo con el entrenamiento para evitar fuga (cargas casi idénticas a las de la sección 3). Los predictores son CP1 a CP3 y `proto_g` (referencia tcp), `service_g` (ninguno) y `state_g` (FIN). Excluimos TTL (separación perfecta artefactual), `tipo_trafico` y `attack_cat` (fuga de la etiqueta).

M1 usa solo los puntajes (AIC 3.734,2; R^2 de McFadden 0,232; AUC en prueba 0,795) y M2 agrega protocolo, servicio y estado (AIC 2.876,5; R^2 0,411; AUC 0,882); la razón de verosimilitud favorece a M2 ($\chi^2 = 871{,}7$; 7 gl; $p < 0{,}001$), que elegimos.

Odds ratios. Con lo demás fijo, un desvío más de CP1 (magnitud del flujo frente a repetición) multiplica las chances de ataque por 5,0, y uno más de CP2 (volumen de tráfico) las reduce un 41 % (Tabla 7). Los OR de las categóricas son condicionales y la colinealidad es alta (VIF ≈ 17–18 en `udp` e INT; $\leq 3{,}6$ en las componentes), por lo que se interpretan solo en su dirección: INT y dns, más chances de ataque; CON_otros, menos. La inestabilidad lo confirma: al rehacer la partición el OR de INT pasó de 93 a 375 y el de udp de 0,42 a 0,14. Así, dns tiene menos ataques que servicio ninguno (32 frente a 49 %) pero OR ajustado 19,1.

Tabla 7. Odds ratios de M2 con IC 95 % por verosimilitud perfilada (componentes: por desvío del puntaje; categóricas: frente a la referencia). Faltan http (1,88), udp (0,14) y las categorías otros.

Término	OR	IC 95 %
CP1	5,01	4,11 – 6,15
CP2	0,59	0,53 – 0,67
CP3	2,54	2,25 – 2,86
Estado INT vs FIN	375,1	107,0 – 1.317,7
Estado CON_otros vs FIN	0,19	0,08 – 0,44
Servicio dns vs ninguno	19,1	9,0 – 42,5

Desempeño en prueba. Con umbral 0,5, M2 logra AUC = 0,882 (IC 95 % de DeLong con `pROC` (Robin et al., 2011): 0,864 – 0,900), exactitud 0,818, sensibilidad 0,915, especificidad 0,713 y precisión 0,775. Domina el falso positivo: 207 normales marcados como ataque (28,7 %) frente a 66 ataques no detectados (8,5 %; Anexo A, Figura A.10), un costo aceptable al detectar intrusiones.

Diagnóstico. No hay separación (convergió sin avisos). Según la distancia de Cook, 166 flujos (4,7 %) superan $4/n$, pero el máximo es 0,019, muy lejos de 1. La calibración es razonable salvo el decil 10, que sobreestima (0,96 contra 0,84; Anexo A, Figura A.11).

Cierre. H4 se confirma: el AUC en prueba es 0,882 y el límite inferior de su IC (0,864)

también supera 0,80; con las componentes solas (M1, 0,795) no se cumpliría. La probabilidad es relativa a esta base (52 % de ataques, sin duplicados, ataques sintéticos): interpretamos odds ratios, no prevalencias.

8. Integración y conclusiones

La Tabla A.11 (Anexo A) integra las técnicas, una fila por técnica. Veredictos:

- **H1, confirmada.** El AF y el cluster de variables dan los mismos tres bloques (ARI = 1,000); el ACP también pide tres componentes, pero no los recupera como ejes puros (secciones 3 y 4).
- **H2, parcialmente confirmada.** El cluster 1 es casi todo normal y el 3 todo ataque, pero los otros cuatro mezclan ambos; además, el cluster 3 sí distingue un tipo (Generic), lo que contradice la segunda parte de la hipótesis (sección 5).
- **H3, parcialmente confirmada.** INT y sin respuesta se asocian con Otros ataques, pero Exploits es casi todo FIN con respuesta, y dns y http no son exclusivos de lo normal (sección 6).
- **H4, confirmada.** El AUC de prueba (0,882) y el límite inferior de su IC superan 0,80; solo con las componentes (M1, 0,795) no se cumpliría (sección 7).

Bloques y clusters. Los clusters se ordenan sobre todo por CP1 ($\eta^2 = 0{,}86$; CP2 y CP3, 0,65) y por los factores (F2 Temporización 0,78, F3 Volumen 0,73, F1 Repetición 0,72): por ejemplo, el cluster 3 tiene F1 = $+3{,}78$ (repetición) y el 2, F2 = $+0{,}88$ (sesiones largas). Es en parte circular, pero el ACM, que no intervino, lo confirma: el cluster 3 es todo INT y sin respuesta y los clusters 1, 2 y 4 se superponen en TCP/FIN.

Sorpresas. (i) La repetición alta no distingue ataques: el cluster 3 es todo ataque y el 6, un tercio. (ii) El cluster 3 aísla Generic. (iii) Todo flujo INT es sin respuesta (913 de 913) y casi todo sin respuesta es INT (913 de 945). (iv) El caso Heywood de `log_spkts`. (v) Los OR categóricos son inestables entre particiones.

Limitaciones. Los ataques son sintéticos y, sin duplicados, las proporciones no son prevalencias: la probabilidad logística es relativa a esta base (52 % de ataques); excluimos TTL por artefacto; los `ct_*` usan ventanas de 100 conexiones, así que los flujos no son independientes; con $n = 5.000$ Bartlett rechaza todo y pesa más el KMO; el ajuste global del AF es flojo; k = 6 empata en silhouette con k = 2, 4 y 5; los terciles del ACM son un criterio estadístico, no sustantivo; las categóricas son colineales en la logística; usamos una sola partición 70/30 (a futuro: testing set oficial, validación cruzada y regularización para estabilizar los OR); y los datos son observacionales: describimos asociaciones, no causas.

Conclusión. Los flujos se organizan en tres patrones, volumen, temporización y repetición, que junto con el estado, el servicio y el protocolo permiten estimar la probabilidad de ataque (AUC 0,882 en prueba), aunque con 28,7 % de los normales marcados como ataque. A nuestro juicio (valoración del grupo), lo más sólido es la estructura de variables, que tres técnicas recuperan, y lo más frágil, la lectura de los grupos y de los odds ratios aislados; el estado de la conexión parece aportar más que cualquier patrón numérico.

Referencias bibliográficas

Greenacre, M. (2017). *Correspondence Analysis in Practice*. Chapman and Hall/CRC, Boca Raton, FL, 3 edition.

Hair, J. F., Black, W. C., Babin, B. J., and Anderson, R. E. (2019). *Multivariate Data Analysis*. Cengage, Andover, Hampshire, 8 edition.

Horn, J. L. (1965). A rationale and test for the number of factors in factor analysis. *Psychometrika*, 30(2):179–185.

Hosmer, D. W., Lemeshow, S., and Sturdivant, R. X. (2013). *Applied Logistic Regression*. Wiley, Hoboken, NJ, 3 edition.

Husson, F., Lê, S., and Pagès, J. (2017). *Exploratory Multivariate Analysis by Example Using R*. Chapman and Hall/CRC, Boca Raton, FL, 2 edition.

Johnson, R. A. and Wichern, D. W. (2007). *Applied Multivariate Statistical Analysis*. Pearson, 6 edition.

Kaiser, H. F. (1974). An index of factorial simplicity. *Psychometrika*, 39(1):31–36.

Kaufman, L. and Rousseeuw, P. J. (1990). *Finding Groups in Data: An Introduction to Cluster Analysis*. Wiley, New York.

Moustafa, N. and Slay, J. (2015). UNSW-NB15: a comprehensive data set for network intrusion detection systems. In *Military Communications and Information Systems Conference (MilCIS)*. IEEE.

Moustafa, N. and Slay, J. (2016). The evaluation of network anomaly detection systems: statistical analysis of the UNSW-NB15 data set and the comparison with the KDD99 data set. *Information Security Journal: A Global Perspective*, 25(1–3):18–31.

R Core Team (2024). *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria.

Revelle, W. (2024). *psych: Procedures for Psychological, Psychometric, and Personality Research*. Northwestern University, Evanston, Illinois. Paquete de R.

Robin, X., Turck, N., Hainard, A., Tiberti, N., Lisacek, F., Sanchez, J.-C., and Müller, M. (2011). pROC: an open-source package for R and S+ to analyze and compare ROC curves. *BMC Bioinformatics*, 12:77.

A. Figuras y tablas complementarias

Este anexo reúne gráficos y tablas que respaldan el cuerpo del informe pero que no son imprescindibles para seguir el razonamiento. Se presentan en el mismo orden que los capítulos.

A.1. Datos

Tabla A.1. Controles de calidad sobre la muestra de 5.000 flujos (cantidad de casos que incumplen cada control).

Control	Casos	Control	Casos
Valores NA	0	TTL fuera de 0 a 255	0
Textos vacíos	0	Ventana TCP fuera de 0 a 65.535	0
Filas duplicadas	0	`dur` = 0 con `spkts` >1	0
Identificadores repetidos	0	`sbytes` <`spkts`	0
Perfiles duplicados sin `id`	0	Indicadores binarios fuera de 0/1	0
Celdas negativas	0	`is_ftp_login` fuera de 0/1	1
Celdas no finitas	0	`label` fuera de normal/ataque	0
Conteos no enteros	0	`label` y `attack_cat` inconsistentes	0

Tabla A.2. Flujos fuera de los límites de Tukey ($1{,}5\times$ RIC) en cada variable de X_num, sobre la escala logarítmica (n = 5.000). En `log_ct_dst_sport_ltm` el rango intercuartílico es nulo (el 90,7 % de los flujos vale 1), de modo que cualquier valor mayor queda marcado.

Variable	Casos	%	Variable	Casos	%
`log_dur`	189	3,8	`log_ct_srv_src`	10	0,2
`log_spkts`	19	0,4	`log_ct_srv_dst`	10	0,2
`log_sbytes`	256	5,1	`log_ct_src_ltm`	127	2,5
`log_dbytes`	1.056	21,1	`log_ct_src_dport_ltm`	581	11,6
`log_sinpkt`	33	0,7	`log_ct_dst_sport_ltm`	466	9,3
`log_sjit`	0	0,0	`log_synack`	44	0,9

A.2. Análisis factorial

Tabla A.3. Diagnóstico de soluciones factoriales (rotación varimax; la oblimin da los mismos valores de comunalidad). "Heywood" indica comunalidad $\geq 0{,}995$ (unicidad $\leq 0{,}005$) en alguna variable. Fuente: elaboración propia con UNSW-NB15.

Factores	Estimador	Heywood	Com. máx.	RMSR	TLI	RMSEA	% var.
3	Minres	Sí	1,025	0,045	0,687	0,214	67,4
3	Ejes principales	Sí	1,095	0,045	0,684	0,215	67,7
3	Máx. verosimilitud	Sí (límite)	0,995	0,059	0,716	0,204	67,0
3	**GLS**	**No**	**0,897**	0,051	0,609	0,239	68,6
4	Minres	Sí	1,029	0,026	0,777	0,180	73,0
4	Máx. verosimilitud	Sí (límite)	0,995	0,032	0,793	0,174	73,6
4	GLS	Sí	1,011	0,028	0,778	0,180	73,6

En todas las soluciones ninguna variable queda sin carga mayor o igual que 0,40 y no hay cargas cruzadas con diferencia menor que 0,20. Con cuatro factores el bloque de repetición de conexiones se divide en dos. La Tabla A.4 reúne los autovalores que respaldan la decisión de retener tres factores.

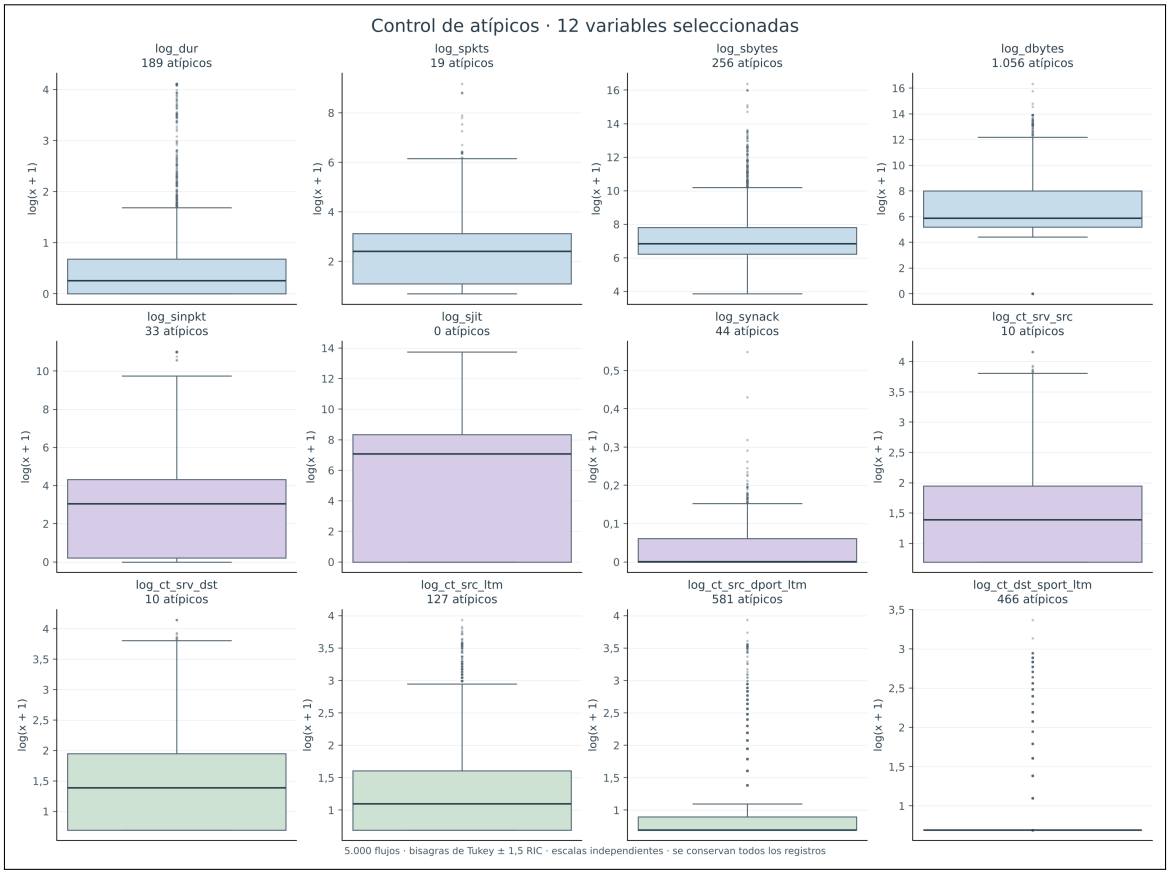


Figura A.1. Diagramas de caja de las 12 variables de X_num en escala logarítmica, con los límites de Tukey ($\pm 1{,}5$ RIC). El título de cada panel indica la cantidad de flujos fuera de los límites. Se conservan todos los registros. Fuente: elaboración propia con UNSW-NB15.

Tabla A.4. Autovalores de la matriz de correlaciones y de la matriz reducida (comunalidades iniciales en la diagonal), y autovalores factoriales observados y simulados del análisis paralelo. Fuente: elaboración propia con UNSW-NB15.

Factor	Autovalor de R	Matriz reducida	Observado (paralelo)	Simulado (paralelo)
1	5,195	4,932	4,606	0,272
2	2,026	1,783	1,398	0,064
3	1,721	1,441	1,106	0,050
4	0,759	0,431	0,127	0,036
5	0,607	0,269	$-0{,}041$	0,024

Tabla A.5. Tabla cruzada entre el corte de Ward en seis grupos (filas) y los clusters de k-means (columnas); ARI = 0,813. Fuente: elaboración propia con UNSW-NB15.

Ward \ k-means	1	2	3	4	5	6
1	56	0	4	37	1.126	72
2	19	98	0	2.063	8	47
3	3	0	0	1	0	142
4	71	285	0	19	0	8
5	749	22	0	11	1	8
6	0	0	143	0	0	7

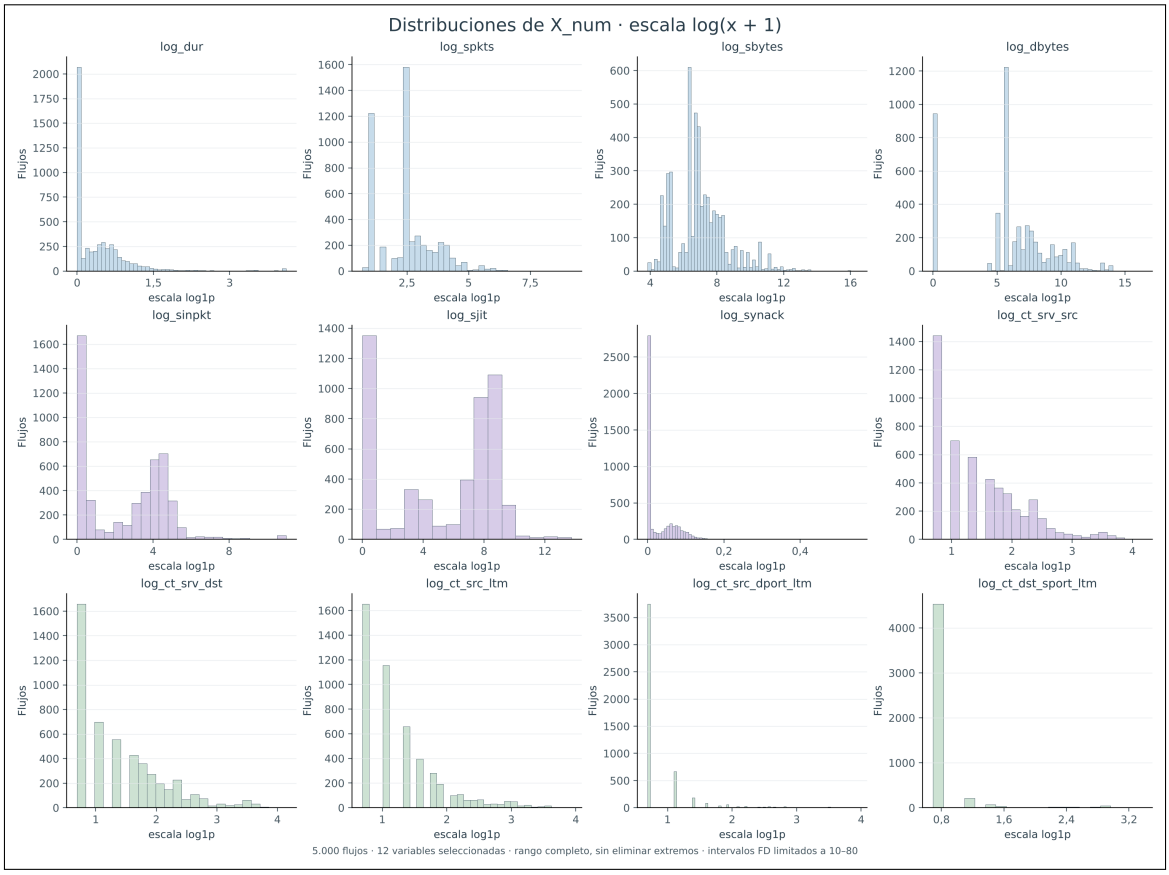


Figura A.2. Histogramas de las 12 variables de X_num tras la transformación $\log(x+1)$. Varias distribuciones de volumen y de temporización son multimodales y las de repetición conservan una cola derecha. Fuente: elaboración propia con UNSW-NB15.

Tabla A.6. Tabla cruzada entre k-means sobre las variables estandarizadas (filas) y k-means sobre los puntajes de las tres componentes principales (columnas); ARI = 0,708. Fuente: elaboración propia con UNSW-NB15.

Variables \ ACP	1	2	3	4	5	6
1	0	2	76	14	1	805
2	0	0	326	21	58	0
3	147	0	0	0	0	0
4	0	9	28	515	1.578	1
5	1	1.126	0	6	0	2
6	95	42	0	71	0	76

Tabla A.7. Cruce entre los clusters y el tipo de tráfico (cantidad de flujos). Fuente: elaboración propia con UNSW-NB15.

Tipo de tráfico	1	2	3	4	5	6
Normal	885	111	0	617	610	185
Exploits	5	179	1	659	73	4
Fuzzers	6	78	2	416	185	62
Reconnaissance	0	4	2	255	84	4
Otros ataques	2	33	142	184	183	29

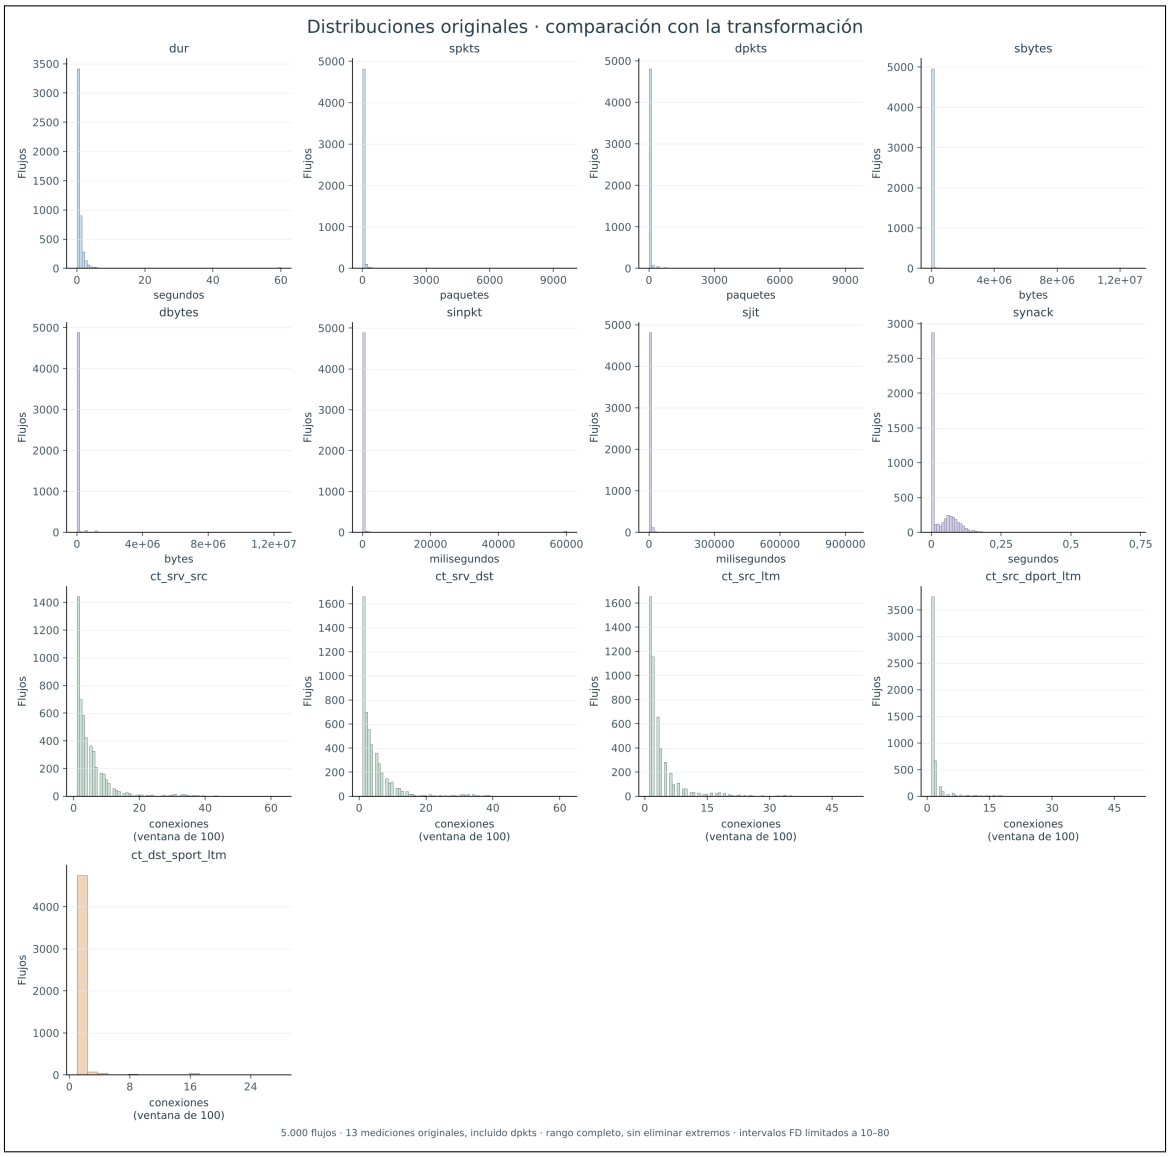


Figura A.3. Histogramas de las variables en su escala original (incluida `dpkts`, excluida de X_num). La concentración cerca de cero y las colas extremas justifican la transformación logarítmica. Fuente: elaboración propia con UNSW-NB15.

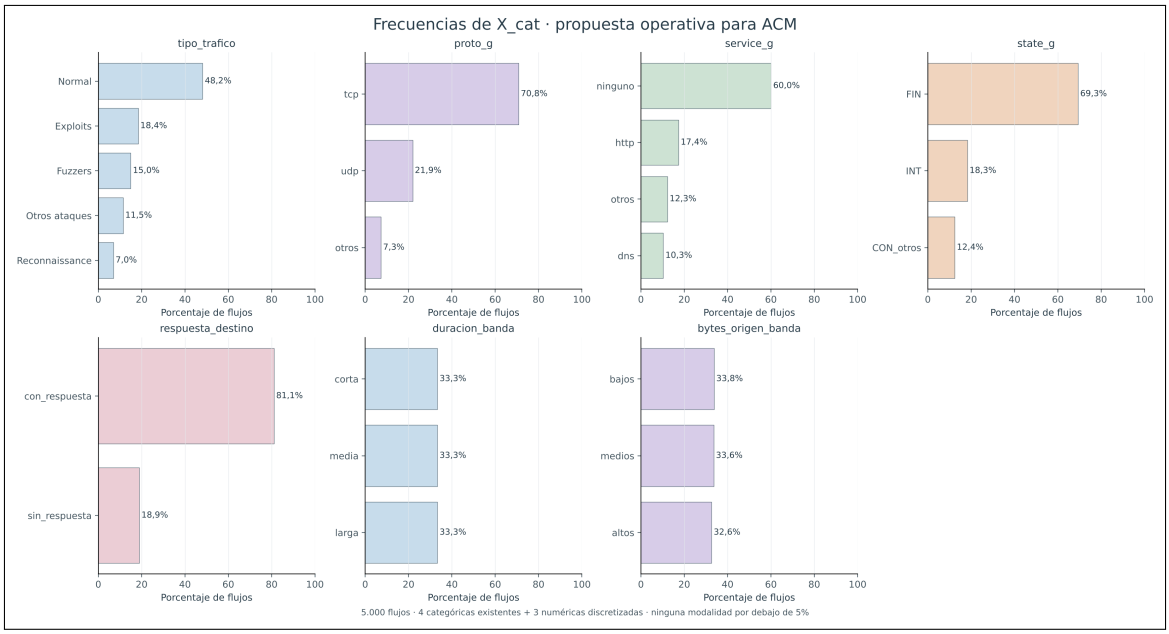


Figura A.4. Frecuencias relativas de las siete variables de X_cat tras agrupar categorías y discretizar tres variables numéricas. Ninguna categoría queda por debajo del 5 %. Fuente: elaboración propia con UNSW-NB15.

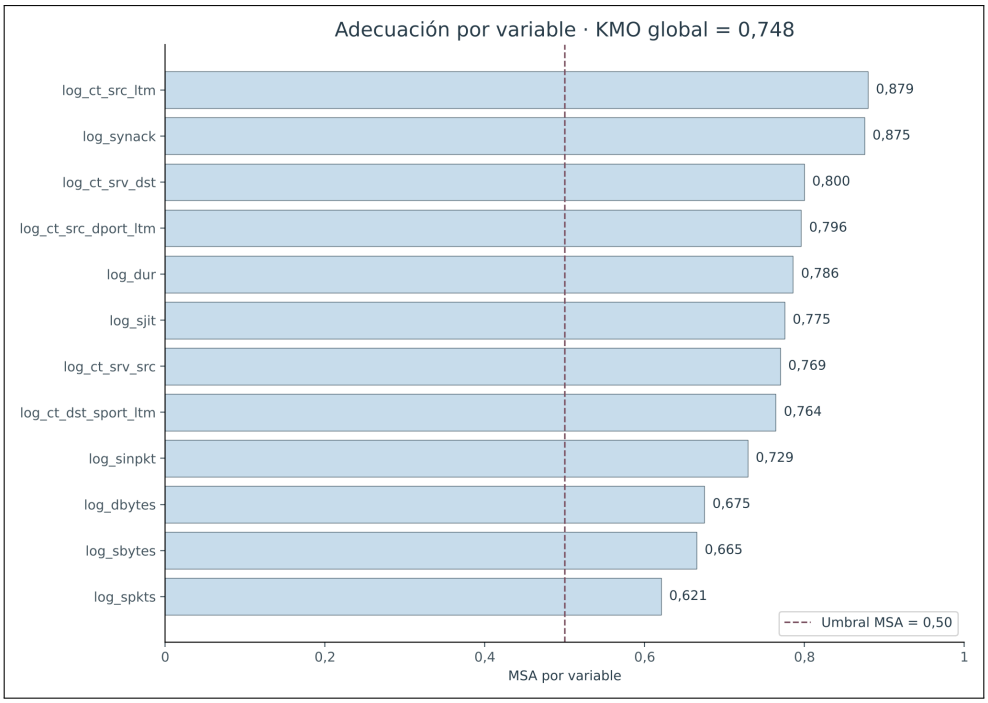


Figura A.5. Medida de adecuación muestral (MSA) por variable, con KMO global de 0,748. Todas superan el umbral de 0,50; la menor es `log_spkts` (0,621). Fuente: elaboración propia con UNSW-NB15.

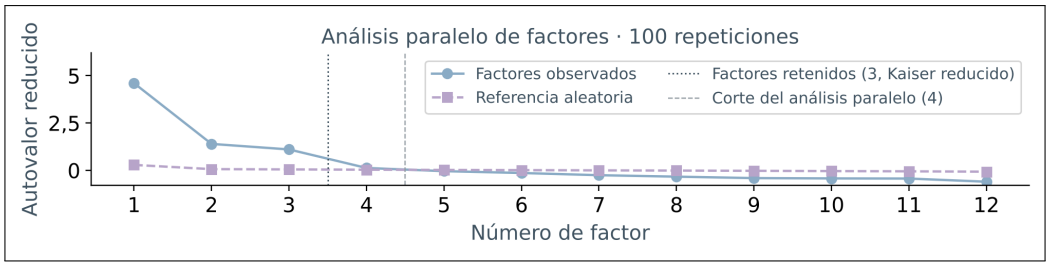


Figura A.6. Análisis paralelo: tres autovalores quedan muy por encima de la referencia aleatoria; el cuarto (0,127) apenas la supera (corte sugerido por el análisis paralelo). Retenemos tres (Kaiser reducido). Fuente: elaboración propia con UNSW-NB15.

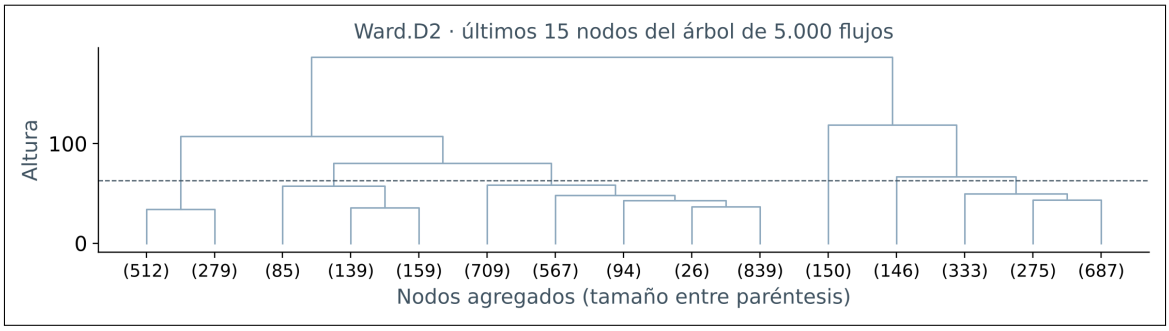


Figura A.7. Dendrograma Ward.D2 de los 5.000 flujos (últimos 15 nodos; entre paréntesis, flujos de cada nodo). La línea punteada indica el corte en seis grupos. Fuente: elaboración propia con UNSW-NB15.

A.3. Análisis de conglomerados

A.4. Análisis de correspondencias

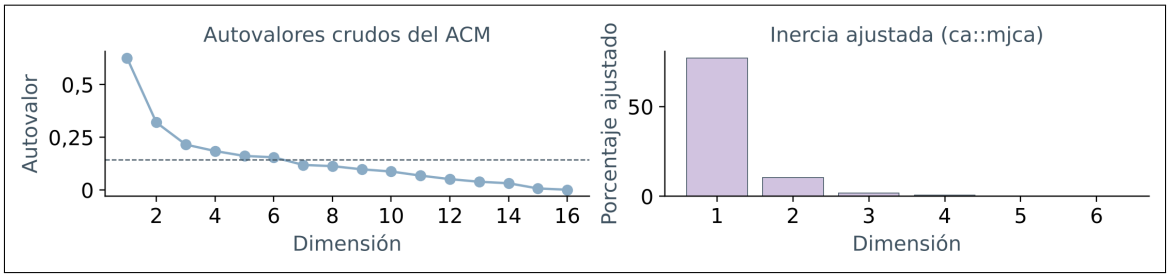


Figura A.8. Izquierda: autovalores crudos del ACM y umbral $1/Q = 0{,}143$ (línea punteada); seis superan el umbral. Derecha: porcentaje de inercia ajustada (Greenacre) por dimensión, con 77,0 % y 10,4 % en las dos primeras. Fuente: elaboración propia con UNSW-NB15.

A.5. Regresión logística

A.6. Integración de las técnicas

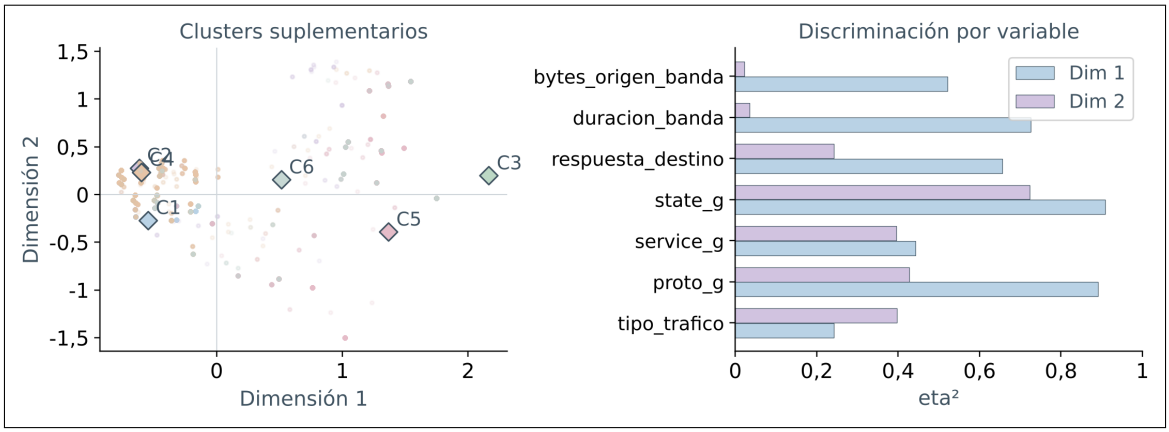


Figura A.9. Izquierda: clusters de la Etapa 3 proyectados como suplementarios (rombos) sobre las observaciones; los clusters 2 y 4 se superponen. Derecha: eta^2 por variable en Dim 1 y Dim 2; `state_g` y `proto_g` dominan la Dim 1. Fuente: elaboración propia con UNSW-NB15.

Tabla A.8. Categorías con mayor contribución (%) y cos2 en las tres primeras dimensiones. La Dim 3 opone http y bytes medios/altos. Fuente: elaboración propia con UNSW-NB15.

Categoría	Ctr 1	Ctr 2	Ctr 3	cos2 1	cos2 2	cos2 3
`state_g`: INT	12,1	9,2	0,0	0,651	0,252	0,000
`respuesta_destino`: sin_respuesta	12,1	8,7	0,0	0,656	0,242	0,000
`duracion_banda`: corta	11,0	0,5	0,0	0,726	0,018	0,000
`proto_g`: udp	9,7	6,9	1,0	0,545	0,199	0,020
`bytes_origen_banda`: bajos	7,8	0,4	0,0	0,520	0,015	0,000
`state_g`: FIN	6,1	0,2	0,1	0,866	0,016	0,007
`proto_g`: tcp	5,9	0,1	0,1	0,886	0,010	0,008
`service_g`: dns	5,7	15,2	3,4	0,277	0,381	0,057
`state_g`: CON_otros	2,5	22,8	0,9	0,127	0,585	0,016
`proto_g`: otros	4,7	12,0	0,3	0,223	0,291	0,005
`tipo_trafico`: Normal	0,1	8,9	6,2	0,004	0,384	0,181
`service_g`: http	2,7	0,5	27,5	0,146	0,015	0,503
`bytes_origen_banda`: altos	2,4	0,0	15,7	0,158	0,000	0,352
`bytes_origen_banda`: medios	1,6	0,5	15,5	0,107	0,018	0,354

Tabla A.9. Razón de correlación η^2 de cada variable con las dos dimensiones retenidas. Fuente: elaboración propia con UNSW-NB15.

Variable	Dim 1	Dim 2
`state_g`	0,909	0,723
`proto_g`	0,891	0,428
`duracion_banda`	0,726	0,035
`respuesta_destino`	0,656	0,242
`bytes_origen_banda`	0,522	0,022
`service_g`	0,442	0,396
`tipo_trafico`	0,242	0,398

Tabla A.10. ACS: perfiles fila de `tipo_trafico` según `state_g` (%). Fuente: elaboración propia con UNSW-NB15.

Tipo de tráfico	CON_otros	FIN	INT
Exploits	1,4	90,4	8,1
Fuzzers	0,3	66,8	33,0
Normal	24,0	70,0	5,9
Otros ataques	3,8	33,9	62,3
Reconnaissance	1,1	72,8	26,1

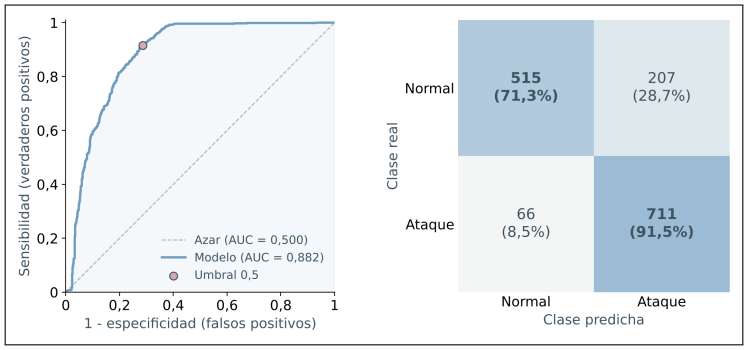


Figura A.10. Curva ROC y matriz de confusión de M2 en la prueba (umbral 0,5). Fuente: elaboración propia con UNSW-NB15.

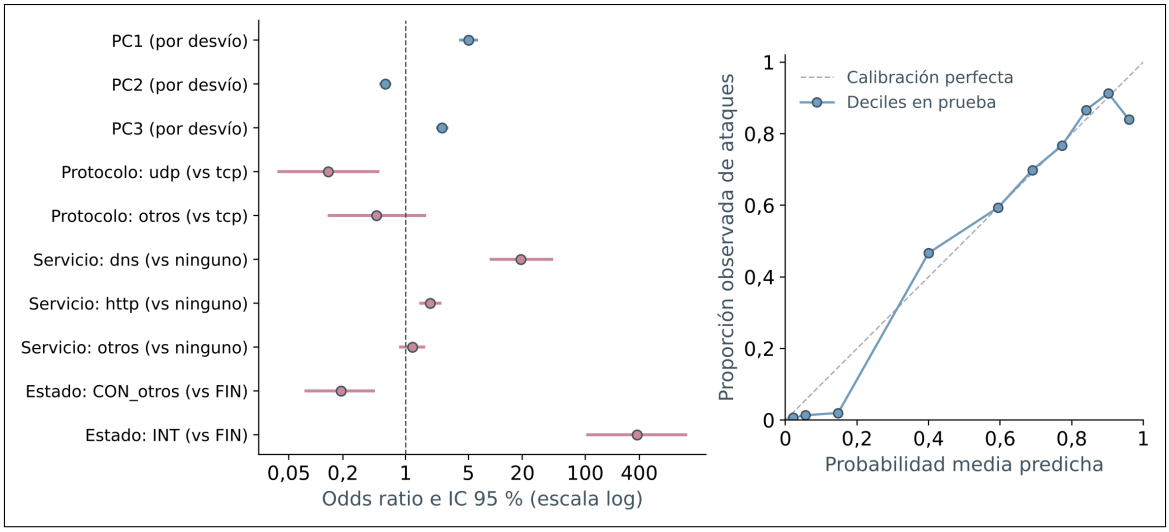


Figura A.11. Izquierda: odds ratios de M2 con IC 95 % (escala logarítmica); los IC de las categóricas, en especial INT y dns, son muy amplios. Derecha: calibración por deciles de probabilidad en la muestra de prueba; los deciles altos sobreestiman levemente la probabilidad de ataque. Fuente: elaboración propia con UNSW-NB15.

Tabla A.11. Integración de las técnicas: estructura hallada, protagonistas y relación con las demás. Fuente: elaboración propia con UNSW-NB15.

Técnica	Estructura	Protagonistas	Coincidencias y discrepancias
ACP (§3)	3 componentes (74,5 %): CP1 magnitud frente a repetición, CP2 volumen de tráfico, CP3 ritmo lento	CP1: `sjit`, `sinpkt` frente a las cinco `ct_*`; CP2: `spkts`, `sbytes`	Aísla la repetición, como el AF; pero sus ejes son mixtos y no separan volumen de temporización
AF (§4)	3 factores (GLS, varimax), 68,6 %: F1 Repetición, F2 Temporización, F3 Volumen	Cargas de 0,54 a 0,91, sin cruces ambiguos	Idéntico al cluster de variables (ARI = 1,000); ajuste global flojo (TLI 0,609)
Cluster de variables (§5)	3 bloques (Ward): temporización, volumen, repetición	Las cinco `ct_*` juntas; `sinpkt`–`sjit` (0,85)	Igual al AF; el ACP mezcla los bloques en cada eje
Cluster de observaciones (§5)	6 grupos (k-means), silhouette 0,333, estructura débil	C1 transferencias voluminosas (1,4 % ataque); C3 ráfagas sin respuesta (100 %); C2 y C6 mal separados	Se ordenan en CP1 y F1; en el ACM, C3 queda aislado en Dim 1. Con puntajes del ACP, ARI = 0,708
ACS y ACM (§6)	ACS: tipo $\times$ estado (V = 0,405). ACM: 2 dim., 41,4 % crudo (87,4 % ajustado)	Dim 1: INT, sin respuesta, UDP frente a FIN y TCP; Dim 2: DNS/CON frente a protocolo *otros*	Dim 1 reproduce el contraste de CP1 y el cluster 3; `tipo_trafico` pesa poco en Dim 1 (η^2 = 0,242) y más en Dim 2 (0,398)
Logística (§7)	M2 con CP1–CP3 y categorías: AUC 0,882 en prueba (IC 95 % 0,864–0,900)	CP1 (OR 5,01), CP3 (2,54), CP2 (0,59); INT, CON_otros (0,19), dns	Coincide con el ACM en INT y CON_otros; dns cambia de signo al ajustar y los OR categóricos son inestables

B. Código fuente

Los scripts se ejecutan desde la carpeta principal del repositorio. Primero se corre `R/ejecutar_todo.R`, que genera las tablas en `resultados/tablas`; luego los scripts de Python dibujan las figuras a partir de esas tablas. Todos los procesos aleatorios usan la semilla 42.

B.1. Scripts de R

`R/00_datos.R` · **Etapa 0: importación, calidad, descriptiva y supuestos**

```r
# ETAPA 0. Ejecutar desde la carpeta principal del proyecto.
# Instalar una sola vez: install.packages(c("readxl", "psych"))
# Ejecutar: source("R/00_datos.R", encoding = "UTF-8")
library(readxl)
library(psych)
set.seed(42)

# 1. Importar el mismo Excel que usamos en el script del diccionario.
ruta_excel <- "muestra_estratificada-simulado-de-ataques.xlsx"
base <- read_excel(path = ruta_excel, sheet = "muestra")
info <- read_excel(path = ruta_excel, sheet = "diccionario")
info <- info[match(names(base), info$variable), ]
stopifnot(!anyNA(info$variable), !anyDuplicated(info$variable))
base_original <- base

diccionario <- data.frame(
  nombre = info$variable,
  descripcion = info$descripcion,
  unidad = info$unidad,
  tipo = ifelse(info$tipo %in% c("continua", "conteo"), "numérica", "categórica")
)
print(dim(base))
print(table(diccionario$tipo))
if (interactive()) View(diccionario)

# Guardar solo las tablas necesarias, con nombres fáciles de identificar.
dir.create("resultados/tablas", recursive = TRUE, showWarnings = FALSE)
dir.create("resultados/figuras", recursive = TRUE, showWarnings = FALSE)
guardar_tabla <- function(tabla, nombre) {
  write.csv(tabla, paste0("resultados/tablas/", nombre, ".csv"),
            row.names = FALSE, fileEncoding = "UTF-8", na = "")
}
guardar_tabla(diccionario, "diccionario_variables")

# 2. Elegir las 12 log_ acordadas para ACP, AF y clustering.
variables_num <- c(
  "log_dur", "log_spkts", "log_sbytes", "log_dbytes", "log_sinpkt", "log_sjit",
  "log_synack", "log_ct_srv_src", "log_ct_srv_dst", "log_ct_src_ltm",
  "log_ct_src_dport_ltm", "log_ct_dst_sport_ltm"
)
X_num <- as.data.frame(base[variables_num])
stopifnot(all(is.finite(as.matrix(X_num))))

# 3. Revisar faltantes, duplicados y valores incompatibles con su definición.
faltantes <- data.frame(variable = names(base), NA_encontrados = colSums(is.na(base)))
faltantes$textos_vacios <- sapply(base, function(x) sum(trimws(as.character(x)) == "", na.rm = TRUE))
columnas_perfil <- setdiff(names(base)[1:45], "id")
columnas_numericas <- names(base)[sapply(base, is.numeric)]
conteos <- info$variable[info$tipo == "conteo"]
valores <- as.matrix(base[columnas_numericas])

calidad <- data.frame(
  control = c("Valores NA", "Textos vacíos", "Filas duplicadas", "ID repetidos",
    "Perfiles originales duplicados sin id", "Celdas negativas", "Celdas no finitas sin NA",
    "Conteos no enteros", "TTL fuera de 0 a 255", "Ventana TCP fuera de 0 a 65535",
    "dur = 0 con spkts > 1 (revisar precisión)", "sbytes < spkts",
    "Indicadores usa_http/is_sm_ips_ports fuera de 0/1", "is_ftp_login fuera de 0/1",
    "label fuera de normal/ataque", "label y attack_cat inconsistentes"),
  cantidad = c(sum(is.na(base)), sum(faltantes$textos_vacios), sum(duplicated(base)),
    sum(duplicated(base$id)), sum(duplicated(base[columnas_perfil])),
    sum(valores < 0, na.rm = TRUE), sum(!is.finite(valores) & !is.na(valores)),
```

```r
    sum(sapply(base[conteos], function(x) sum(abs(x - round(x)) > 1e-8, na.rm = TRUE))),
    sum(base$sttl < 0 | base$sttl > 255 | base$dttl < 0 | base$dttl > 255, na.rm = TRUE),
    sum(base$swin < 0 | base$swin > 65535 | base$dwin < 0 | base$dwin > 65535, na.rm = TRUE),
    sum(base$dur == 0 & base$spkts > 1), sum(base$sbytes < base$spkts),
    sum(!base$usa_http %in% c(0, 1)) + sum(!base$is_sm_ips_ports %in% c(0, 1)),
    sum(!base$is_ftp_login %in% c(0, 1)), sum(!base$label %in% c("normal", "ataque")),
    sum((base$attack_cat == "Normal") != (base$label == "normal")))
)
ftp_revision <- base[!base$is_ftp_login %in% c(0, 1), c("id", "is_ftp_login", "ct_ftp_cmd")]
guardar_tabla(faltantes, "faltantes")
guardar_tabla(calidad, "calidad")
guardar_tabla(ftp_revision, "ftp_revision")
print(calidad)
print(ftp_revision)

# Atípicos: límites de Tukey sobre las 12 log_, sin borrar observaciones.
# fivenum usa bisagras de Tukey: pueden diferir de quantile cuando hay empates.
atipicos <- matrix(FALSE, nrow = nrow(base), ncol = length(variables_num))
limites <- data.frame()
for (i in seq_along(variables_num)) {
  variable <- variables_num[i]
  x <- X_num[[variable]]
  cinco <- fivenum(x)
  q1 <- cinco[2]
  q3 <- cinco[4]
  ric <- q3 - q1
  inferior <- q1 - 1.5 * ric
  superior <- q3 + 1.5 * ric
  atipicos[, i] <- x < inferior | x > superior
  limites <- rbind(limites, data.frame(variable = variable, q1_tukey = q1,
    mediana = cinco[3], q3_tukey = q3, limite_inferior = inferior, limite_superior = superior,
    bigote_inferior = min(x[x >= inferior & x <= superior]),
    bigote_superior = max(x[x >= inferior & x <= superior]), n_atipicos = sum(atipicos[, i])))
}
revision_atipicos <- data.frame(id = base$id, n_atipicos_original = base$n_atipicos,
                                n_atipicos_revision_12 = rowSums(atipicos))
guardar_tabla(limites, "atipicos_limites")
guardar_tabla(revision_atipicos, "atipicos_por_flujo")
cat("Flujos con atípicos en las 12 variables:", sum(rowSums(atipicos) > 0), "\n")

# Registrar qué se hace con cada problema; conservar la base recibida.
decisiones <- data.frame(
  tema = c("Faltantes", "Duplicados", "Valores incompatibles", "Código FTP",
           "Ceros y servicio ninguno", "Atípicos", "Indicador anterior"),
  decision = c("No imputar: no se encontraron faltantes en esta base.",
    "No eliminar filas: no se encontraron duplicados en esta base.",
    "Registrar los controles y revisar incidencias antes de cualquier corrección.",
    "Conservar el código 4 y el flujo; is_ftp_login no entra en X_num ni X_cat.",
    "Conservar: pueden ser valores estructurales, no faltantes.",
    "Conservar todos los flujos; un extremo no demuestra error ni ataque.",
    "No sobrescribir n_atipicos; guardar la revisión de las 12 variables por separado.")
)
guardar_tabla(decisiones, "decisiones_calidad")

# 4. Descriptiva de las 47 numéricas; se incluyen dpkts y las versiones log_.
numericas <- diccionario$nombre[diccionario$tipo == "numérica"]
resumen <- data.frame()
for (variable in numericas) {
  x <- base[[variable]]
  q <- quantile(x, c(0, .25, .5, .75, 1), na.rm = TRUE, names = FALSE, type = 7)
  resumen <- rbind(resumen, data.frame(variable = variable, media = mean(x, na.rm = TRUE),
    desvio = sd(x, na.rm = TRUE), minimo = q[1], q1 = q[2], mediana = q[3], q3 = q[4],
    maximo = q[5], ceros = sum(x == 0, na.rm = TRUE)))
}
guardar_tabla(resumen, "resumen_numerico")
print(resumen)

categoricas <- diccionario$nombre[diccionario$tipo == "categórica"]
frecuencias <- data.frame()
for (variable in categoricas) {
  tabla <- table(base[[variable]], useNA = "ifany")
  frecuencias <- rbind(frecuencias, data.frame(variable = variable, categoria = names(tabla),
    frecuencia = as.integer(tabla), porcentaje = 100 * as.integer(tabla) / nrow(base)))
```

```r
}
guardar_tabla(frecuencias, "frecuencias_categoricas")

# 5. Piloto con psych: Pearson, Bartlett, KMO y MSA por variable.
correlaciones <- cor(X_num, method = "pearson")
kmo <- KMO(correlaciones)
bartlett <- cortest.bartlett(correlaciones, n = nrow(X_num))
msa <- data.frame(variable = names(kmo$MSAi), msa = as.numeric(kmo$MSAi))
piloto <- data.frame(determinante = det(correlaciones), kmo_global = kmo$MSA,
  msa_minima = min(kmo$MSAi), bartlett_chi2 = bartlett$chisq, bartlett_gl = bartlett$df,
  bartlett_p_calculado = bartlett$p.value,
  bartlett_p_informe = ifelse(bartlett$p.value < .001, "< 0,001", as.character(bartlett$p.value)))
guardar_tabla(data.frame(variable = rownames(correlaciones), correlaciones), "correlaciones")
guardar_tabla(msa, "msa_por_variable")
guardar_tabla(piloto, "piloto_supuestos")
print(piloto)
print(msa)
if (kmo$MSA < .6 || min(kmo$MSAi) < .5 || det(correlaciones) <= 1e-5)
  warning("Revisar el piloto; no se cambia X_num automáticamente.")

# 6. Congelar X_cat: cuatro categorías existentes y tres discretizaciones.
# Los terciles no usan la etiqueta de ataque para elegir los cortes.
cortes_dur <- unname(quantile(base$dur, c(1/3, 2/3), type = 7))
cortes_bytes <- unname(quantile(base$sbytes, c(1/3, 2/3), type = 7))
X_cat <- as.data.frame(base[c("tipo_trafico", "proto_g", "service_g", "state_g")])
X_cat$respuesta_destino <- ifelse(base$dpkts == 0, "sin_respuesta", "con_respuesta")
X_cat$duracion_banda <- cut(base$dur, c(-Inf, cortes_dur, Inf), labels = c("corta", "media", "larga"))
X_cat$bytes_origen_banda <- cut(base$sbytes, c(-Inf, cortes_bytes, Inf), labels = c("bajos", "medios", "
    ↪ altos"))
X_cat[] <- lapply(X_cat, factor)
frecuencias_cat <- data.frame()
for (variable in names(X_cat)) {
  tabla <- table(X_cat[[variable]])
  frecuencias_cat <- rbind(frecuencias_cat, data.frame(variable = variable,
    categoria = names(tabla), frecuencia = as.integer(tabla), porcentaje = 100 * as.integer(tabla) / nrow(
    ↪ base)))
}
stopifnot(!anyNA(X_cat), all(frecuencias_cat$porcentaje >= 5))
guardar_tabla(frecuencias_cat, "frecuencias_X_cat")
guardar_tabla(data.frame(variable = c("dur", "sbytes"), corte_1 = c(cortes_dur[1], cortes_bytes[1]),
  corte_2 = c(cortes_dur[2], cortes_bytes[2])), "cortes_discretizacion")
guardar_tabla(data.frame(conjunto = c(rep("X_num", ncol(X_num)), rep("X_cat", ncol(X_cat))),
  variable = c(names(X_num), names(X_cat))), "conjuntos_congelados")

# 7. Guardar la base común y los conjuntos sin crear una carpeta datos ni archivos md.
stopifnot(identical(base, base_original))
saveRDS(base, "resultados/base_limpia.rds")
saveRDS(list(X_num = X_num, X_cat = X_cat, id = base$id, semilla = 42,
  cortes_dur = cortes_dur, cortes_bytes = cortes_bytes,
  estado_X_cat = "Congelado para los análisis de la Parte 2"), "resultados/conjuntos_congelados.rds")
cat("Base y conjuntos guardados en resultados. Excel original conservado.\n")
cat("Gráficos: ejecutar en Python el archivo python/graficos_etapa0.py.\n")
```

`R/01_acp.R` · Etapa 1: análisis de componentes principales

```r
# ETAPA 1. ACP sobre las 12 log_, desde la carpeta principal del proyecto.
set.seed(42)
base <- readRDS("resultados/base_limpia.rds")
conjuntos <- readRDS("resultados/conjuntos_congelados.rds")
X_num <- conjuntos$X_num
guardar <- function(x, nombre) write.csv(x, paste0("resultados/tablas/", nombre, ".csv"),
  row.names = FALSE, fileEncoding = "UTF-8")

# Estandarizar evita que las mayores varianzas determinen las componentes.
acp <- prcomp(X_num, scale. = TRUE)
acp_sin_escalar <- prcomp(X_num, scale. = FALSE)
autovalores <- acp$sdev^2
tabla_autovalores <- data.frame(componente = seq_along(autovalores), autovalor = autovalores,
  porcentaje = 100 * autovalores / sum(autovalores),
  acumulado = 100 * cumsum(autovalores) / sum(autovalores))
guardar(tabla_autovalores, "acp_autovalores")
```

```r
guardar(data.frame(variable = names(X_num), varianza = sapply(X_num, var)), "acp_varianzas")
guardar(data.frame(version = c("estandarizado", "sin_estandarizar"),
  porcentaje_CP1 = c(100 * autovalores[1] / sum(autovalores),
    100 * acp_sin_escalar$sdev[1]^2 / sum(acp_sin_escalar$sdev^2))), "acp_comparacion_escala")

# Kaiser sugiere tres; se contrasta el resultado con el codo y el significado de los ejes.
n_componentes <- sum(autovalores > 1)
correlaciones <- cor(X_num, acp$x)
contribuciones <- 100 * acp$rotation^2
cos2 <- correlaciones^2
guardar(data.frame(variable = rownames(correlaciones), correlaciones[, 1:n_componentes]), "acp_
    ↪ correlaciones")
guardar(data.frame(variable = rownames(contribuciones), contribuciones[, 1:n_componentes]), "acp_
    ↪ contribuciones")
guardar(data.frame(variable = rownames(cos2), cos2[, 1:n_componentes]), "acp_cos2")
puntajes <- acp$x[, 1:n_componentes, drop = FALSE]
guardar(data.frame(id = base$id, tipo_trafico = base$tipo_trafico, puntajes), "acp_puntajes")

# Distancia en el espacio retenido, ajustada por la varianza de cada componente.
distancia <- rowSums(sweep(puntajes, 2, acp$sdev[1:n_componentes], "/")^2)
extremos <- order(distancia, decreasing = TRUE)[1:3]
guardar(data.frame(base[extremos, c("id", "tipo_trafico", "dur", "spkts", "dpkts", "sbytes", "dbytes")],
  puntajes[extremos, , drop = FALSE], distancia = distancia[extremos]), "acp_extremos")
saveRDS(list(modelo = acp, n_componentes = n_componentes, puntajes = puntajes), "resultados/acp.rds")
print(tabla_autovalores)
cat("Componentes retenidas:", n_componentes, "\n")
```

R/02_af.R · Etapa 2: análisis factorial

```r
# ETAPA 2. Análisis factorial exploratorio y revisión de soluciones impropias (casos Heywood).
# La comparación completa de 3 vs 4 factores x métodos x rotaciones está en R/aux_diagnostico_af.R.
library(psych)
set.seed(42)
conjuntos <- readRDS("resultados/conjuntos_congelados.rds")
X_num <- conjuntos$X_num
guardar <- function(x, nombre) write.csv(x, paste0("resultados/tablas/", nombre, ".csv"),
  row.names = FALSE, fileEncoding = "UTF-8")
R <- cor(X_num)
kmo <- KMO(R)
bartlett <- cortest.bartlett(R, n = nrow(X_num))
stopifnot(det(R) > .00001, kmo$MSA >= .6, min(kmo$MSAi) >= .5, bartlett$p.value < .05)

# 1. Cuántos factores: evidencia gráfica (análisis paralelo) y analítica (Kaiser sobre la
# matriz reducida). El análisis paralelo no se dibuja en R: se exporta para Matplotlib.
options(mc.cores = 1)
paralelo <- fa.parallel(X_num, fa = "both", fm = "minres", n.iter = 100,
  quant = .95, plot = FALSE)
guardar(data.frame(dimension = seq_along(paralelo$fa.values),
  factor_observado = paralelo$fa.values, factor_simulado = paralelo$fa.sim,
  componente_observado = paralelo$pc.values, componente_simulado = paralelo$pc.sim), "af_paralelo")

# Kaiser aplicado a la matriz reducida (comunalidades iniciales SMC en la diagonal): es el
# criterio coherente con el AF, porque trabaja solo con la varianza común.
Rreducida <- R
diag(Rreducida) <- smc(R)
autovalores_reducida <- eigen(Rreducida, symmetric = TRUE, only.values = TRUE)$values
n_kaiser <- sum(autovalores_reducida > 1)

# Se retienen 3 factores aunque el análisis paralelo sugiere 4. Motivos (ver docs/validacion_decisiones.md):
#  - Con n = 5000 el análisis paralelo detecta cualquier estructura por encima del azar; el 4.º
#    autovalor observado (0,127) es 10 veces menor que 1 y el codo cae después del 3.º.
#  - Kaiser sobre la matriz reducida y el ACP (Etapa 1) dan 3, igual que la hipótesis H1.
#  - El 4.º factor solo parte el bloque ct_* en dos: queda con 2 variables fuertes (ct_srv_*),
#    lo que es síntoma de sobreextracción, y esos dos subfactores correlacionan 0,62 en oblimin.
n_paralelo <- paralelo$nfact
n_factores <- n_kaiser
stopifnot(n_factores == 3)

# 2. Caso Heywood. Se contrastan estimadores sobre los mismos 3 factores y la misma rotación.
# Un estimador "falla" si alguna comunalidad llega a 1 o más (unicidad <= 0.005, el límite de ML).
# Los avisos de psych ("ultra-Heywood") son esperables aquí: se informan, no se ocultan.
```

```r
ajustar <- function(metodo) suppressWarnings(fa(X_num, nfactors = n_factores, fm = metodo,
  rotate = "varimax", scores = "regression", n.obs = nrow(X_num)))
metodos <- c("minres", "pa", "ml", "gls")
fits <- lapply(setNames(metodos, metodos), ajustar)
diagnostico <- do.call(rbind, lapply(metodos, function(m) {
  f <- fits[[m]]
  data.frame(metodo = m, n_factores = n_factores, comunalidad_max = max(f$communality),
    unicidad_min = min(f$uniquenesses), variable_extrema = names(which.min(f$uniquenesses)),
    heywood = any(f$uniquenesses <= .005), rmsr = f$rms)
}))
guardar(diagnostico, "af_diagnostico_minres")
print(diagnostico)

# 3. Estimador final: GLS (mínimos cuadrados generalizados) con varimax.
# minres, pa y ML dan comunalidad ~1 (o mayor) para log_spkts; GLS la estima en torno a 0,87
# y todas las unicidades quedan lejos de cero. Es un remedio estándar ante un Heywood
# (cambiar de estimador) que no obliga a sacar una variable de X_num ni a fijar límites arbitrarios.
af <- fits[["gls"]]
cargas <- unclass(af$loadings)
# Se ordenan los factores por varianza explicada (psych ya los entrega así) y se renombran F1..F3.
colnames(cargas) <- paste0("F", seq_len(n_factores))
colnames(af$scores) <- paste0("Factor", seq_len(n_factores))

# Nombres: cada factor toma el bloque (H1) de las variables que más pesan en él.
bloque_h1 <- c(log_spkts = "Volumen", log_sbytes = "Volumen", log_dbytes = "Volumen",
  log_dur = "Temporización", log_sinpkt = "Temporización", log_sjit = "Temporización",
  log_synack = "Temporización", log_ct_srv_src = "Repetición de conexiones",
  log_ct_srv_dst = "Repetición de conexiones", log_ct_src_ltm = "Repetición de conexiones",
  log_ct_src_dport_ltm = "Repetición de conexiones", log_ct_dst_sport_ltm = "Repetición de conexiones")
asignado <- colnames(cargas)[apply(abs(cargas), 1, which.max)]
nombres_factores <- sapply(colnames(cargas), function(f) {
  b <- unique(bloque_h1[rownames(cargas)[asignado == f]])
  stopifnot(length(b) == 1) # si un factor mezcla bloques, hay que revisar el nombre a mano
  b
})

patron <- cargas
patron[abs(patron) < .4] <- NA # la consigna pide ocultar cargas menores a 0,40
diferencia <- apply(abs(cargas), 1, function(x) { x <- sort(x, decreasing = TRUE); x[1] - x[2] })
n_cargas <- rowSums(abs(cargas) >= .4)
comunalidad <- as.numeric(af$communality)
unicidad <- as.numeric(af$uniquenesses)
guardar(data.frame(variable = rownames(cargas), cargas, comunalidad = comunalidad,
  unicidad = unicidad, diferencia = diferencia, cargas_mayores_040 = n_cargas), "af_cargas_completas")
guardar(data.frame(variable = rownames(cargas), patron, comunalidad = comunalidad,
  unicidad = unicidad), "af_patron")
guardar(data.frame(factor = colnames(cargas), nombre = unname(nombres_factores)), "af_nombres_factores")
guardar(data.frame(factor = colnames(cargas), suma_cargas2 = colSums(cargas^2),
  porcentaje_total = 100 * colSums(cargas^2) / ncol(X_num),
  porcentaje_comun = 100 * colSums(cargas^2) / sum(cargas^2)), "af_varianza")
residuos <- R - tcrossprod(cargas)
rmsr <- sqrt(mean(residuos[lower.tri(residuos)]^2))
guardar(data.frame(metodo = "gls", n_factores = n_factores, n_sugerido_paralelo = n_paralelo,
  n_kaiser_reducida = n_kaiser, rmsr = rmsr, tli = af$TLI, rmsea = af$RMSEA[["RMSEA"]],
  chi2 = unname(af$STATISTIC), gl = af$dof, p_modelo = af$PVAL,
  comunalidad_min = min(comunalidad), unicidad_min = min(unicidad),
  unicidades_limite = sum(unicidad <= .00501),
  cruces_ambiguos = sum(n_cargas > 1 & diferencia < .2)), "af_ajuste")
guardar(data.frame(id = conjuntos$id, af$scores), "af_puntajes")
saveRDS(list(modelo = af, n_factores = n_factores, cargas = cargas, paralelo = paralelo,
  metodo = "gls", nombres = nombres_factores, diagnostico = diagnostico), "resultados/af.rds")
print(af$loadings, cutoff = .4)
print(af$uniquenesses)
```

`R/aux_diagnostico_af.R` · Etapa 2 (auxiliar): diagnóstico del caso Heywood

```r
# AUXILIAR (no forma parte de ejecutar_todo.R). Diagnóstico del caso Heywood en el AF.
# Ejecutar desde la raíz del repo:  Rscript R/aux_diagnostico_af.R
# Compara 3 vs 4 factores x (minres, ml, pa) x (varimax, oblimin) y guarda
# resultados/tablas/af_diagnostico_comparativo.csv y af_diagnostico_autovalores.csv.
# Sirve de evidencia para justificar cuántos factores retiene R/02_af.R.
```

```r
library(psych)
set.seed(42)
X <- readRDS("resultados/conjuntos_congelados.rds")$X_num
R <- cor(X)
p <- ncol(X)

# Bloques esperados por H1 (docs/etapa0_pregunta_hipotesis.md); solo para chequear interpretabilidad.
bloque_h1 <- c(log_spkts = "vol", log_sbytes = "vol", log_dbytes = "vol",
  log_dur = "tmp", log_sinpkt = "tmp", log_sjit = "tmp", log_synack = "tmp",
  log_ct_srv_src = "ctx", log_ct_srv_dst = "ctx", log_ct_src_ltm = "ctx",
  log_ct_src_dport_ltm = "ctx", log_ct_dst_sport_ltm = "ctx")

# 1. Autovalores: ¿es sustantivo el 4.º factor?
# Matriz reducida = R con la diagonal reemplazada por las comunalidades iniciales (SMC).
smc_ <- smc(R)
Rred <- R; diag(Rred) <- smc_
av_red <- eigen(Rred, symmetric = TRUE, only.values = TRUE)$values
av_cor <- eigen(R, symmetric = TRUE, only.values = TRUE)$values
set.seed(42)
pa <- suppressWarnings(fa.parallel(X, fa = "both", fm = "minres", n.iter = 100,
  quant = .95, plot = FALSE))
# Con n = 5000 el análisis paralelo detecta casi cualquier cosa por encima del azar:
# se agrega la varianza que aporta cada autovalor (autovalor reducido / suma de positivos).
aut <- data.frame(factor = 1:p, autovalor_R = av_cor, autovalor_reducida_smc = av_red,
  pct_var_total = 100 * av_cor / p,
  pct_var_comun = 100 * pmax(av_red, 0) / sum(pmax(av_red, 0)),
  fa_observado = pa$fa.values, fa_simulado = pa$fa.sim)
write.csv(aut, "resultados/tablas/af_diagnostico_autovalores.csv", row.names = FALSE, fileEncoding = "UTF-8
    ↪ ")
cat("\n== Autovalores (los 6 primeros) ==\n"); print(round(aut[1:6, ], 3), row.names = FALSE)
cat("Sugerencia del análisis paralelo (minres):", pa$nfact, "factores.\n")
cat("Kaiser sobre la matriz reducida (autovalor > 1):", sum(av_red > 1), "factores.\n")
cat("Autovalores reducidos > 0:", sum(av_red > 0), "\n")

# 2. Comparativo de soluciones
filas <- list()
for (k in 3:4) for (m in c("minres", "ml", "pa", "gls")) for (rot in c("varimax", "oblimin")) {
  aviso <- character()
  f <- withCallingHandlers(
    tryCatch(fa(X, nfactors = k, fm = m, rotate = rot, n.obs = nrow(X)), error = function(e) NULL),
    warning = function(w) { aviso <<- c(aviso, conditionMessage(w)); invokeRestart("muffleWarning") })
  if (is.null(f)) next
  L <- unclass(f$loadings)
  com <- f$communality
  uni <- f$uniquenesses
  ord <- t(apply(abs(L), 1, sort, decreasing = TRUE))
  dif <- ord[, 1] - ord[, 2]
  n04 <- rowSums(abs(L) >= .4)
  # Interpretabilidad: cada variable al factor de mayor carga; ¿cada factor agrupa un solo bloque H1?
  asig <- apply(abs(L), 1, which.max)
  # Cuántos bloques de H1 quedan recuperados exactamente (un factor = un bloque completo).
  grupos <- split(rownames(L), asig)
  puros <- sum(sapply(grupos, function(v) {
    b <- unique(bloque_h1[v]); length(b) == 1 && length(v) == sum(bloque_h1 == b) }))
  prop <- f$Vaccounted
  filas[[length(filas) + 1]] <- data.frame(
    n_factores = k, metodo = m, rotacion = rot,
    heywood = any(com >= 1 | uni <= .005),
    comunalidad_max = max(com), unicidad_min = min(uni),
    rmsr = f$rms, tli = f$TLI, rmsea = f$RMSEA[1],
    pct_var_acum = 100 * tail(prop["Cumulative Var", ], 1),
    sin_carga_040 = sum(n04 == 0),
    cruces_dif_menor_020 = sum(n04 > 1 & dif < .2),
    bloques_H1_recuperados = puros,
    avisos = length(aviso))
}
comp <- do.call(rbind, filas)
write.csv(comp, "resultados/tablas/af_diagnostico_comparativo.csv", row.names = FALSE, fileEncoding = "UTF
    ↪ -8")
cat("\n== Comparativo (varimax y oblimin) ==\n")
print(format(comp, digits = 3), row.names = FALSE)

# 3. Estructura de la solución de 3 y 4 factores con minres/varimax (la del análisis paralelo)
```

```r
for (k in 3:4) {
  f <- suppressWarnings(fa(X, nfactors = k, fm = "minres", rotate = "varimax"))
  cat("\n== minres + varimax,", k, "factores (cargas < 0,40 ocultas) ==\n")
  print(f$loadings, cutoff = .4, digits = 2)
  cat("Comunalidades:\n"); print(round(f$communality, 3))
}
# En 4 factores, ¿cuánto aporta el 4.º y qué hace? Correlación entre variables ct_* de cada puerto/servicio:
cat("\nCorrelaciones dentro del bloque ct_*:\n"); print(round(R[grep("ct_", rownames(R)), grep("ct_",
    ↪ colnames(R))], 2))
cat("\nCorrelación log_spkts con log_sbytes:", round(R["log_spkts", "log_sbytes"], 3),
    "| con log_dbytes:", round(R["log_spkts", "log_dbytes"], 3), "\n")

# 4. Factores correlacionados (oblimin, ML): ¿los dos subfactores ct_* del 4.º factor son separables?
f4o <- suppressWarnings(fa(X, nfactors = 4, fm = "ml", rotate = "oblimin"))
cat("\nCorrelación entre factores (ML, oblimin, 4 factores); los dos subfactores ct_* son los de mayor
    ↪ correlación:\n")
print(round(f4o$Phi, 2))

# 5. Sensibilidad (SOLO informativa; X_num no se modifica): ¿desaparece el Heywood sin log_spkts?
Xs <- X[, names(X) != "log_spkts"]
cat("\nSensibilidad sin log_spkts, 3 factores varimax:\n")
for (m in c("minres", "ml", "pa", "gls")) {
  f <- suppressWarnings(fa(Xs, nfactors = 3, fm = m, rotate = "varimax"))
  cat(sprintf("  %-7s comunalidad max = %.3f | unicidad min = %.3f | RMSR = %.3f\n", m,
              max(f$communality), min(f$uniquenesses), f$rms))
}
```

R/03_cluster.R · Etapa 3: conglomerados de observaciones y de variables

```r
# ETAPA 3. Ward y k-means sobre las 12 log_ estandarizadas.
library(cluster)
set.seed(42)
base <- readRDS("resultados/base_limpia.rds")
conjuntos <- readRDS("resultados/conjuntos_congelados.rds")
X_num <- conjuntos$X_num
guardar <- function(x, nombre) write.csv(x, paste0("resultados/tablas/", nombre, ".csv"),
  row.names = FALSE, fileEncoding = "UTF-8")
Z <- scale(X_num)
distancias <- dist(Z, method = "euclidean")
jerarquico <- hclust(distancias, method = "ward.D2")

# Codo: suma de cuadrados dentro de grupos. Silhouette sobre los 5.000 flujos.
metricas <- data.frame()
modelos_km <- list()
for (k in 2:8) {
  set.seed(42)
  km <- kmeans(Z, centers = k, nstart = 25, iter.max = 100)
  ward <- cutree(jerarquico, k)
  wss_ward <- 0
  for (g in 1:k) {
    grupo <- Z[ward == g, , drop = FALSE]
    wss_ward <- wss_ward + sum(sweep(grupo, 2, colMeans(grupo), "-")^2)
  }
  metricas <- rbind(metricas, data.frame(k = k, wss_ward = wss_ward, wss_kmeans = km$tot.withinss,
    silhouette_ward = mean(silhouette(ward, distancias)[, 3]),
    silhouette_kmeans = mean(silhouette(km$cluster, distancias)[, 3])))
  modelos_km[[as.character(k)]] <- km
  cat("Evaluado k =", k, "\n")
}
guardar(metricas, "cluster_metricas")

# Mayor silhouette de k-means entre los candidatos; el informe contrasta con el codo y Ward.
k_elegido <- metricas$k[which.max(metricas$silhouette_kmeans)]
km <- modelos_km[[as.character(k_elegido)]]
ward <- cutree(jerarquico, k_elegido)
guardar(as.data.frame.matrix(table(Ward = ward, Kmeans = km$cluster)), "cluster_cruce_ward_kmeans")

# Comparación de particiones sin depender del número arbitrario de las etiquetas.
ari <- function(a, b) {
  t <- table(a, b)
  observado <- sum(choose(t, 2))
```

```
  esperado <- sum(choose(rowSums(t), 2)) * sum(choose(colSums(t), 2)) / choose(sum(t), 2)
  maximo <- (sum(choose(rowSums(t), 2)) + sum(choose(colSums(t), 2))) / 2
  (observado - esperado) / (maximo - esperado)
}

# Los puntajes de ACP conservan la ponderación por sus autovalores: no se reescalan.
acp <- readRDS("resultados/acp.rds")
set.seed(42)
km_acp <- kmeans(acp$puntajes, centers = k_elegido, nstart = 25, iter.max = 100)
ward_acp <- cutree(hclust(dist(acp$puntajes), method = "ward.D2"), k_elegido)
guardar(as.data.frame.matrix(table(Kmeans_log = km$cluster, Kmeans_ACP = km_acp$cluster)), "cluster_cruce_
    ↪ acp")
guardar(as.data.frame.matrix(table(Ward_log = ward, Ward_ACP = ward_acp)), "cluster_cruce_ward_acp")
guardar(data.frame(k = k_elegido, ARI_ward_kmeans = ari(ward, km$cluster),
  ARI_kmeans_acp = ari(km$cluster, km_acp$cluster), ARI_ward_acp = ari(ward, ward_acp)), "cluster_
    ↪ comparaciones")

originales <- sub("^log_", "", names(X_num))
guardar(aggregate(base[originales], list(cluster = km$cluster), mean), "cluster_medias_originales")
guardar(aggregate(as.data.frame(Z), list(cluster = km$cluster), mean), "cluster_medias_estandarizadas")
guardar(data.frame(cluster = 1:k_elegido, n = as.integer(table(km$cluster)),
  porcentaje = 100 * as.integer(table(km$cluster)) / nrow(base)), "cluster_tamanos")
guardar(as.data.frame(table(cluster = km$cluster, tipo_trafico = base$tipo_trafico)), "cluster_contexto")
guardar(aggregate(as.numeric(base$label == "ataque"), list(cluster = km$cluster), mean), "cluster_
    ↪ proporcion_ataques")

# Cluster de variables: distancia euclidiana entre sus columnas estandarizadas, Ward.D2.
jerarquico_vars <- hclust(dist(t(Z)), method = "ward.D2")
guardar(data.frame(variable = names(X_num), bloque = cutree(jerarquico_vars, 3)), "cluster_variables_
    ↪ bloques")
guardar(data.frame(izquierda = jerarquico$merge[, 1], derecha = jerarquico$merge[, 2],
  altura = jerarquico$height), "cluster_dendrograma")
guardar(data.frame(izquierda = jerarquico_vars$merge[, 1], derecha = jerarquico_vars$merge[, 2],
  altura = jerarquico_vars$height), "cluster_dendrograma_variables")
base$cluster <- factor(km$cluster)
base$cluster_ward <- factor(ward)
base$cluster_acp <- factor(km_acp$cluster)
saveRDS(base, "resultados/base_con_clusters.rds")
guardar(data.frame(id = base$id, cluster = km$cluster, cluster_ward = ward,
  cluster_acp = km_acp$cluster), "cluster_asignaciones")
saveRDS(list(k = k_elegido, kmeans = km, jerarquico = jerarquico,
  jerarquico_variables = jerarquico_vars), "resultados/clustering.rds")
print(metricas)
cat("k elegido:", k_elegido, "\n")
```

`R/04_acm.R` · Etapa 4: correspondencias simple y múltiples

```
# ETAPA 4. ACS, ACM y proyección suplementaria del cluster.
library(ca)
library(FactoMineR)
set.seed(42)
base <- readRDS("resultados/base_con_clusters.rds")
conjuntos <- readRDS("resultados/conjuntos_congelados.rds")
X_cat <- conjuntos$X_cat
guardar <- function(x, nombre) write.csv(x, paste0("resultados/tablas/", nombre, ".csv"),
  row.names = FALSE, fileEncoding = "UTF-8")

# Las siete variables activas ya incluyen tres numéricas discretizadas en Etapa 0.
# Sus modalidades superan 5%; no se fusionan categorías adicionales.
frecuencias <- read.csv("resultados/tablas/frecuencias_X_cat.csv")
stopifnot(all(frecuencias$porcentaje >= 5), all(sapply(X_cat, is.factor)))

# ACS: tipo de tráfico y estado agrupado, para estudiar la tercera hipótesis.
tabla <- table(X_cat$tipo_trafico, X_cat$state_g)
acs <- ca::ca(tabla, nd = 2)
chi <- chisq.test(tabla, correct = FALSE)
guardar(data.frame(tipo_trafico = rownames(tabla), unclass(tabla)), "acs_contingencia")
guardar(data.frame(tipo_trafico = rownames(tabla), unclass(100 * prop.table(tabla, 1))), "acs_porcentajes_
    ↪ fila")
guardar(data.frame(dimension = seq_along(acs$sv), autovalor = acs$sv^2,
  porcentaje = 100 * acs$sv^2 / sum(acs$sv^2)), "acs_inercia")
```

```r
guardar(data.frame(chi2 = unname(chi$statistic), gl = unname(chi$parameter), p = chi$p.value,
  cramer_v = sqrt(unname(chi$statistic) / (sum(tabla) * min(nrow(tabla) - 1, ncol(tabla) - 1))),
  frecuencia_esperada_min = min(chi$expected)), "acs_asociacion")
guardar(data.frame(categoria = rownames(tabla),
  sweep(acs$rowcoord[, 1:2, drop = FALSE], 2, acs$sv[1:2], "*")), "acs_filas")
guardar(data.frame(categoria = colnames(tabla),
  sweep(acs$colcoord[, 1:2, drop = FALSE], 2, acs$sv[1:2], "*")), "acs_columnas")

# Cluster es suplementario: no interviene en la construcción de los ejes.
datos_acm <- data.frame(X_cat, cluster = base$cluster)
Q <- ncol(X_cat)
J <- sum(sapply(X_cat, nlevels))
acm <- FactoMineR::MCA(datos_acm, quali.sup = ncol(datos_acm), ncp = J - Q, graph = FALSE)
ajustado <- ca::mjca(X_cat, nd = NA, lambda = "adjusted")
indicador <- ca::mjca(X_cat, nd = NA, lambda = "indicator")
# ca 0.72 entrega valores singulares: al cuadrarlos se obtienen los autovalores.
stopifnot(max(abs(indicador$sv^2 - acm$eig[, 1])) < 1e-8)
autovalores <- data.frame(dimension = seq_len(nrow(acm$eig)), autovalor = acm$eig[, 1],
  porcentaje_crudo = acm$eig[, 2], acumulado_crudo = acm$eig[, 3],
  autovalor_ajustado = 0, porcentaje_ajustado = 0)
n_aj <- length(ajustado$sv)
autovalores$autovalor_ajustado[1:n_aj] <- ajustado$sv^2
autovalores$porcentaje_ajustado[1:n_aj] <- 100 * ajustado$inertia.e
autovalores$acumulado_ajustado <- cumsum(autovalores$porcentaje_ajustado)
guardar(autovalores, "acm_autovalores")
guardar(data.frame(Q = Q, J = J, inercia_cruda = J / Q - 1,
  umbral = 1 / Q, ejes_sobre_umbral = sum(acm$eig[, 1] > 1 / Q),
  inercia_total_ajustada = ajustado$inertia.t,
  porcentaje_plano_ajustado = sum(autovalores$porcentaje_ajustado[1:2])), "acm_resumen")

# Se conservan todos los resultados; el informe interpreta el plano de dos dimensiones.
categorias <- ajustado$levelnames
coord <- data.frame(categoria = categorias, acm$var$coord)
contrib <- data.frame(categoria = categorias, acm$var$contrib)
cos2 <- data.frame(categoria = categorias, acm$var$cos2)
guardar(coord, "acm_categorias_coordenadas")
guardar(contrib, "acm_categorias_contribuciones")
guardar(cos2, "acm_categorias_cos2")
guardar(data.frame(variable = rownames(acm$var$eta2), acm$var$eta2), "acm_eta2")
guardar(data.frame(cluster = levels(base$cluster), acm$quali.sup$coord), "acm_cluster_suplementario")
guardar(data.frame(cluster = levels(base$cluster), acm$quali.sup$cos2), "acm_cluster_cos2")
guardar(data.frame(id = base$id, cluster = base$cluster, acm$ind$coord[, 1:2]), "acm_individuos")

# Cruces para interpretar tres asociaciones con frecuencias observadas, sin causalidad.
for (variable in c("respuesta_destino", "duracion_banda", "bytes_origen_banda")) {
  t <- table(X_cat$tipo_trafico, X_cat[[variable]])
  guardar(data.frame(tipo_trafico = rownames(t), unclass(100 * prop.table(t, 1))), paste0("acm_cruce_",
    ↪ variable))
}
saveRDS(list(acs = acs, acm = acm, ajustado = ajustado, dimensiones_interpretadas = 2), "resultados/
    ↪ correspondencias.rds")
print(autovalores)
print(acm$var$eta2[, 1:2])
```

`R/05_integracion.R` · Etapa 6: integración de técnicas

```r
# ETAPA 6. Síntesis de resultados de las técnicas multivariadas.
set.seed(42)
base <- readRDS("resultados/base_con_clusters.rds")
X <- readRDS("resultados/conjuntos_congelados.rds")$X_num
acp <- readRDS("resultados/acp.rds")
af <- readRDS("resultados/af.rds")
km <- readRDS("resultados/clustering.rds")
guardar <- function(x, nombre) write.csv(x, paste0("resultados/tablas/", nombre, ".csv"),
  row.names = FALSE, fileEncoding = "UTF-8")

# Evidencia de la hipótesis de asociaciones, con tamaños del efecto.
asociaciones <- data.frame()
for (variable in c("proto_g", "service_g", "state_g")) {
  t <- table(base$tipo_trafico, base[[variable]])
  prueba <- chisq.test(t, correct = FALSE)
```

```r
  asociaciones <- rbind(asociaciones, data.frame(variable = variable,
    chi2 = unname(prueba$statistic), gl = unname(prueba$parameter), p = prueba$p.value,
    cramer_v = sqrt(unname(prueba$statistic) / (sum(t) * min(dim(t) - 1)))))
}
guardar(asociaciones, "integracion_asociaciones")

# Todas las cifras de la tabla salen de los objetos y tablas ya calculados (nada escrito a mano).
# Formato argentino: coma decimal.
fmt <- function(x, d = 2) formatC(x, format = "f", digits = d, decimal.mark = ",")
leer <- function(nombre) read.csv(paste0("resultados/tablas/", nombre, ".csv"), fileEncoding = "UTF-8")
ari <- function(a, b) { # índice de Rand ajustado entre dos particiones
  t <- table(a, b)
  observado <- sum(choose(t, 2))
  esperado <- sum(choose(rowSums(t), 2)) * sum(choose(colSums(t), 2)) / choose(sum(t), 2)
  maximo <- (sum(choose(rowSums(t), 2)) + sum(choose(colSums(t), 2))) / 2
  (observado - esperado) / (maximo - esperado)
}

var_acp <- sum(acp$modelo$sdev[seq_len(acp$n_componentes)]^2) / sum(acp$modelo$sdev^2) * 100
ajuste_af <- leer("af_ajuste")
var_af <- sum(leer("af_varianza")$porcentaje_total)
heywood_final <- ajuste_af$unicidades_limite > 0 || ajuste_af$unicidad_min <= 0
v_cramer <- asociaciones$cramer_v[asociaciones$variable == "state_g"]
inercia_acm <- leer("acm_resumen")$porcentaje_plano_ajustado
cmp <- leer("cluster_comparaciones")
sil <- leer("cluster_metricas")
sil_k <- sil$silhouette_kmeans[sil$k == km$k]
# ¿Los bloques del cluster de variables coinciden con los factores del AF?
bloques_vars <- leer("cluster_variables_bloques")
factor_dominante <- apply(abs(af$cargas), 1, which.max)
ari_bloques_af <- ari(bloques_vars$bloque, factor_dominante[bloques_vars$variable])

integracion <- data.frame(
  tecnica = c("ACP", "AF", "Clustering", "ACS", "ACM"),
  estructura = c(
    paste0(acp$n_componentes, " componentes; ", fmt(var_acp), "% de varianza"),
    paste0(af$n_factores, " factores (", toupper(af$metodo), ", varimax); ", fmt(var_af),
      "% de la varianza total; ", ifelse(heywood_final, "con unicidad en el límite",
      paste0("sin caso Heywood (unicidad mínima ", fmt(ajuste_af$unicidad_min, 3), ")"))),
    paste0("Tres bloques de variables y ", km$k, " grupos de observaciones"),
    paste0("Tipo de tráfico por estado; V de Cramér = ", fmt(v_cramer, 3)),
    paste0("Plano de dos dimensiones; ", fmt(inercia_acm), "% de inercia ajustada")),
  interpretacion = c(
    "Ejes mixtos: magnitud del flujo frente a repetición (CP1), volumen de tráfico (CP2) y ritmo lento (CP3)",
    paste0(paste(af$nombres, collapse = ", "), " (cargas >= 0,40; cruces ambiguos = ",
      ajuste_af$cruces_ambiguos, ")"),
    paste0("El AF reconoce los bloques (ARI bloques de variables vs. factores = ", fmt(ari_bloques_af, 3),
      "); ARI Ward/KM = ", fmt(cmp$ARI_ward_kmeans, 3), ", silhouette = ", fmt(sil_k, 3),
      "; con puntajes de ACP el ARI frente a k-means es ", fmt(cmp$ARI_kmeans_acp, 3), " (las CP cambian fronteras)"),
    "Normal-CON_otros y Exploits-FIN coinciden con asociaciones del ACM",
    "Dim 1: conexión efímera sin respuesta frente a sesión TCP completa; Dim 2: DNS/UDP con estado CON frente a protocolo otros no establecido")
)
guardar(integracion, "integracion_tecnicas")
print(integracion)
```

R/06_logistica.R · Regresión logística

```r
# ETAPA 6. Regresión logística: ¿es ataque (1) o normal (0)?
# Ejecutar desde la carpeta principal del proyecto: Rscript R/06_logistica.R
#
# Diseño (decidido por el grupo/orquestador):
#  - Validación: partición estratificada por label, 70 % entrenamiento / 30 % prueba,
#    dentro de la muestra de 5.000 flujos. El testing set original de UNSW-NB15 no está
#    en el repositorio y habría que prepararlo igual que la muestra.
#  - Predictores: los 3 puntajes del ACP + proto_g, service_g, state_g.
#  - Prohibidos: TTL (sttl, dttl, ttl_origen, perfil_estado_ttl, ct_state_ttl: separación
#    perfecta por artefacto del laboratorio), tipo_trafico, attack_cat y n_atipicos
#    (son la respuesta "disfrazada" o derivan de ella).
```

```r
#  - El ACP se reajusta SOLO con el entrenamiento para que el conjunto de prueba no
#    influya en los puntajes (evita fuga de información).
library(MASS)   # confint() por verosimilitud perfilada para glm
library(pROC)
set.seed(42)

base <- readRDS("resultados/base_limpia.rds")
conjuntos <- readRDS("resultados/conjuntos_congelados.rds")
X_num <- conjuntos$X_num
acp_completo <- readRDS("resultados/acp.rds")
n_comp <- acp_completo$n_componentes   # 3 componentes (Kaiser), como en el informe
dir.create("resultados/tablas", recursive = TRUE, showWarnings = FALSE)
guardar <- function(x, nombre) write.csv(x, paste0("resultados/tablas/log_reg_", nombre, ".csv"),
  row.names = FALSE, fileEncoding = "UTF-8")
coma <- function(x, d = 3) formatC(x, format = "f", digits = d)

# 1. Respuesta: ataque = 1, normal = 0 (en la base label es texto "ataque"/"normal").
stopifnot(all(base$label %in% c("ataque", "normal")))
base$y <- as.integer(base$label == "ataque")

# 2. Partición 70/30 estratificada por attack_cat (10 categorías), no solo por label.
# Por qué: la muestra de 5.000 se armó estratificando por attack_cat; volver a estratificar
# así respeta el diseño muestral y deja cada tipo de ataque (incluso los raros, como Worms
# con 6 flujos) en la misma proporción en entrenamiento y prueba. label queda balanceado
# automáticamente porque es función de attack_cat (Normal = normal, el resto = ataque).
# Dentro de cada categoría van round(0,7 * n) flujos al entrenamiento y el resto a prueba.
idx_train <- unlist(lapply(split(seq_len(nrow(base)), base$attack_cat), function(i)
  i[sample.int(length(i), size = round(0.7 * length(i)))]))
idx_train <- sort(idx_train)
idx_test <- setdiff(seq_len(nrow(base)), idx_train)
stopifnot(length(intersect(idx_train, idx_test)) == 0)
# Ninguna categoría puede quedar vacía en prueba ni en entrenamiento.
n_cat <- table(base$attack_cat, ifelse(seq_len(nrow(base)) %in% idx_train, "entrenamiento", "prueba"))
stopifnot(all(n_cat > 0), n_cat["Worms", "entrenamiento"] == 4, n_cat["Worms", "prueba"] == 2)
conjunto <- ifelse(seq_len(nrow(base)) %in% idx_train, "entrenamiento", "prueba")

# Resumen general (n y % de ataques por conjunto)
particion <- data.frame(conjunto = c("entrenamiento", "prueba"),
  n = c(length(idx_train), length(idx_test)),
  n_ataques = c(sum(base$y[idx_train]), sum(base$y[idx_test])),
  pct_ataques = c(100 * mean(base$y[idx_train]), 100 * mean(base$y[idx_test])))
guardar(particion, "particion")
# Comparación de proporciones por attack_cat entre ambos conjuntos
cats <- rownames(n_cat)[order(-rowSums(n_cat))]
comp_cat <- data.frame(attack_cat = cats, n_total = as.integer(rowSums(n_cat)[cats]),
  n_entrenamiento = as.integer(n_cat[cats, "entrenamiento"]), n_prueba = as.integer(n_cat[cats, "prueba"]),
  pct_entrenamiento = 100 * n_cat[cats, "entrenamiento"] / sum(n_cat[, "entrenamiento"]),
  pct_prueba = 100 * n_cat[cats, "prueba"] / sum(n_cat[, "prueba"]))
comp_cat$pct_dentro_entrenamiento <- 100 * comp_cat$n_entrenamiento / comp_cat$n_total
guardar(comp_cat, "particion_attack_cat")
# Ids de cada partición (id, attack_cat, label, conjunto)
guardar(data.frame(id = base$id, attack_cat = base$attack_cat, label = base$label,
  conjunto = conjunto), "particion_ids")
# Excel con las 68 columnas de la muestra (la hoja original NO se modifica):
# hojas entrenamiento, prueba y resumen. base es exactamente la hoja `muestra`.
if (requireNamespace("writexl", quietly = TRUE)) {
  writexl::write_xlsx(list(entrenamiento = as.data.frame(base[idx_train, setdiff(names(base), "y")]),
    prueba = as.data.frame(base[idx_test, setdiff(names(base), "y")]), resumen = comp_cat),
    "resultados/muestra_particion_70_30.xlsx")
} else cat("Paquete writexl no instalado: install.packages(\"writexl\") para exportar la partición\n")
print(particion); print(comp_cat)

# 3. ACP reajustado SOLO con el entrenamiento; la prueba se proyecta con predict(), que
# usa las medias y desvíos del entrenamiento.
acp_tr <- prcomp(X_num[idx_train, ], scale. = TRUE)
# Los signos de una componente son arbitrarios. Se alinean con el ACP del informe (5.000):
# si la carga de entrenamiento apunta al lado contrario, se invierte la componente.
signos <- sapply(1:n_comp, function(k)
  sign(sum(acp_tr$rotation[, k] * acp_completo$modelo$rotation[, k])))
cat("Signo relativo al ACP completo (1 = igual, -1 = invertido):", signos, "\n")
acp_tr$rotation[, 1:n_comp] <- sweep(acp_tr$rotation[, 1:n_comp, drop = FALSE], 2, signos, "*")
# Se recalculan los puntajes de entrenamiento con la rotación ya corregida.
nombres_cp <- paste0("PC", 1:n_comp)
```

```r
P_tr <- predict(acp_tr, X_num[idx_train, ])[, 1:n_comp]
P_te <- predict(acp_tr, X_num[idx_test, ])[, 1:n_comp]
colnames(P_tr) <- colnames(P_te) <- nombres_cp

# Comparación de cargas: entrenamiento vs. ACP con los 5.000.
dif_cargas <- acp_tr$rotation[, 1:n_comp] - acp_completo$modelo$rotation[, 1:n_comp]
comp_cargas <- data.frame(variable = rownames(acp_tr$rotation),
  setNames(as.data.frame(acp_tr$rotation[, 1:n_comp]), paste0(nombres_cp, "_entrenamiento")),
  setNames(as.data.frame(acp_completo$modelo$rotation[, 1:n_comp]), paste0(nombres_cp, "_completo")))
guardar(comp_cargas, "acp_cargas_comparacion")
resumen_cargas <- data.frame(componente = nombres_cp, signo_invertido = signos == -1,
  max_dif_absoluta = apply(abs(dif_cargas), 2, max),
  correlacion = sapply(1:n_comp, function(k)
    cor(acp_tr$rotation[, k], acp_completo$modelo$rotation[, k])),
  pct_varianza_entrenamiento = 100 * acp_tr$sdev[1:n_comp]^2 / sum(acp_tr$sdev^2))
guardar(resumen_cargas, "acp_cargas_resumen")
print(resumen_cargas)

# 4. Categóricas con categoría de referencia explícita: la más frecuente de cada una,
# así las demás se comparan contra la situación "típica" y el error estándar de la
# referencia es el menor posible: tcp (70,8 %), ninguno (60,0 %), FIN (69,3 %).
ref <- function(x, nivel) relevel(factor(x), ref = nivel)
datos <- data.frame(y = base$y, id = base$id, P = rbind(P_tr, P_te)[order(c(idx_train, idx_test)), ],
  proto_g = ref(base$proto_g, "tcp"), service_g = ref(base$service_g, "ninguno"),
  state_g = ref(base$state_g, "FIN"))
names(datos) <- sub("^P\\.", "", names(datos))
train <- datos[idx_train, ]
test <- datos[idx_test, ]
stopifnot(identical(train$id, base$id[idx_train]))

# 5. Dos modelos anidados. M1: solo los puntajes. M2: M1 + categóricas.
M1 <- glm(y ~ PC1 + PC2 + PC3, data = train, family = binomial)
aviso <- NULL
M2 <- withCallingHandlers(
  glm(y ~ PC1 + PC2 + PC3 + proto_g + service_g + state_g, data = train, family = binomial),
  warning = function(w) { aviso <<- c(aviso, conditionMessage(w)); invokeRestart("muffleWarning") })
if (!is.null(aviso)) cat("AVISO al ajustar M2:", aviso, "\n")

# 6. Comparación: AIC, devianza, test de razón de verosimilitud y AUC en prueba.
auc_prueba <- function(m) auc(roc(test$y, as.numeric(predict(m, test, type = "response")),
  levels = c(0, 1), direction = "<", quiet = TRUE))
mcfadden <- function(m) 1 - m$deviance / m$null.deviance
lr <- anova(M1, M2, test = "Chisq")
comparacion <- data.frame(modelo = c("M1: puntajes ACP", "M2: puntajes ACP + proto + service + state"),
  gl_residuales = c(M1$df.residual, M2$df.residual), parametros = c(length(coef(M1)), length(coef(M2))),
  AIC = c(AIC(M1), AIC(M2)), BIC = c(BIC(M1), BIC(M2)),
  devianza = c(deviance(M1), deviance(M2)),
  LR_chi2 = c(NA, lr$Deviance[2]), LR_gl = c(NA, lr$Df[2]), LR_p = c(NA, lr$`Pr(>Chi)`[2]),
  AUC_prueba = c(as.numeric(auc_prueba(M1)), as.numeric(auc_prueba(M2))),
  pseudoR2_McFadden = c(mcfadden(M1), mcfadden(M2)))
guardar(comparacion, "comparacion_modelos")
print(comparacion)

# 7. Elección: M2 si mejora el AIC y el LR es significativo (la ganancia no es azar);
# si no, M1 por parsimonia. La decisión sale de los números, no se fija a mano.
elegido <- if (AIC(M2) < AIC(M1) && lr$`Pr(>Chi)`[2] < 0.05) "M2" else "M1"
modelo <- if (elegido == "M2") M2 else M1
cat("Modelo elegido:", elegido, "\n")

# 8. Coeficientes, OR e IC 95 % por verosimilitud perfilada (más fiable que Wald cuando
# hay categorías raras o coeficientes grandes). Se incluye también el IC de Wald.
sm <- summary(modelo)$coefficients
ic_perfil <- suppressMessages(confint(modelo))
se <- sm[, 2]
coefs <- data.frame(termino = rownames(sm), estimacion = sm[, 1], error_estandar = se,
  z = sm[, 3], p = sm[, 4], OR = exp(sm[, 1]),
  OR_IC95_inf = exp(ic_perfil[, 1]), OR_IC95_sup = exp(ic_perfil[, 2]),
  OR_Wald_IC95_inf = exp(sm[, 1] - 1.96 * se), OR_Wald_IC95_sup = exp(sm[, 1] + 1.96 * se),
  tipo_IC = "verosimilitud perfilada (Wald en columnas aparte)")
guardar(coefs, "coeficientes")
# Los OR de PC1-PC3 son "por cada desvío (1 unidad estandarizada) del puntaje", porque
# el puntaje de cada componente tiene desvío = sdev de la componente: el OR por 1 desvío
# del puntaje es exp(beta * sdev). Se guarda también esa versión, que es la comparable.
```

```r
sdev_tr <- acp_tr$sdev[1:n_comp]
or_desvio <- data.frame(termino = nombres_cp, desvio_puntaje = sdev_tr,
  OR_por_unidad = exp(coef(modelo)[nombres_cp]),
  OR_por_desvio = exp(coef(modelo)[nombres_cp] * sdev_tr),
  OR_desvio_IC95_inf = exp(ic_perfil[nombres_cp, 1] * sdev_tr),
  OR_desvio_IC95_sup = exp(ic_perfil[nombres_cp, 2] * sdev_tr))
guardar(or_desvio, "or_por_desvio")
print(coefs[, 1:8]); print(or_desvio)

# 9. Desempeño en prueba con umbral 0,5. AUC con IC 95 % de DeLong.
p_te <- as.numeric(predict(modelo, test, type = "response"))
roc_te <- roc(test$y, p_te, levels = c(0, 1), direction = "<", quiet = TRUE)
ic_auc <- ci.auc(roc_te, method = "delong")
guardar(data.frame(AUC = as.numeric(auc(roc_te)), IC95_inf = ic_auc[1], IC95_sup = ic_auc[3],
  metodo_IC = "DeLong", modelo = elegido), "auc")
pred <- as.integer(p_te >= 0.5)
VP <- sum(pred == 1 & test$y == 1); VN <- sum(pred == 0 & test$y == 0)
FP <- sum(pred == 1 & test$y == 0); FN <- sum(pred == 0 & test$y == 1)
guardar(data.frame(real = c("normal", "normal", "ataque", "ataque"),
  predicho = c("normal", "ataque", "normal", "ataque"), n = c(VN, FP, FN, VP)), "confusion")
metricas <- data.frame(umbral = 0.5, exactitud = (VP + VN) / length(pred),
  sensibilidad = VP / (VP + FN), especificidad = VN / (VN + FP),
  precision = VP / (VP + FP), F1 = 2 * VP / (2 * VP + FP + FN))
guardar(metricas, "metricas")
print(metricas); print(ic_auc)

# Curva ROC (puntos para graficar) y probabilidades predichas en prueba.
guardar(data.frame(umbral = roc_te$thresholds, fpr = 1 - roc_te$specificities,
  tpr = roc_te$sensitivities), "roc_curva")
guardar(data.frame(id = test$id, y = test$y, p = p_te), "predicciones_prueba")

# 10. Calibración por deciles de probabilidad predicha (en prueba).
dec <- cut(p_te, breaks = unique(quantile(p_te, seq(0, 1, .1))), include.lowest = TRUE, labels = FALSE)
calib <- do.call(rbind, lapply(sort(unique(dec)), function(d) data.frame(decil = d,
  n = sum(dec == d), p_media = mean(p_te[dec == d]), prop_observada = mean(test$y[dec == d]))))
guardar(calib, "calibracion")
print(calib)

# 11. Multicolinealidad: VIF de cada columna de la matriz de diseño y correlaciones.
# (Las dummies de un mismo factor se correlacionan entre sí por construcción.)
mm <- model.matrix(modelo)[, -1, drop = FALSE]
vif <- sapply(seq_len(ncol(mm)), function(j) 1 / (1 - summary(lm(mm[, j] ~ mm[, -j]))$r.squared))
guardar(data.frame(termino = colnames(mm), VIF = vif), "vif")
guardar(data.frame(termino = colnames(mm), round(cor(mm), 4)), "correlaciones_predictores")
print(data.frame(termino = colnames(mm), VIF = round(vif, 2)))

# 12. Separación: coeficientes enormes, EE gigantes o probabilidades ajustadas en 0/1.
ajustadas <- fitted(modelo)
separacion <- data.frame(
  max_abs_coef = max(abs(coef(modelo))), max_error_estandar = max(se),
  ajustadas_menor_1e8 = sum(ajustadas < 1e-8), ajustadas_mayor_1_menos_1e8 = sum(ajustadas > 1 - 1e-8),
  aviso_glm = ifelse(is.null(aviso), "sin avisos", paste(unique(aviso), collapse = " | ")),
  convergio = modelo$converged, iteraciones = modelo$iter)
guardar(separacion, "separacion")
print(separacion)
# Tablas cruzadas categoría x respuesta en entrenamiento: celdas vacías delatarían separación.
cruces <- do.call(rbind, lapply(c("proto_g", "service_g", "state_g"), function(v) {
  t <- table(train[[v]], train$y)
  data.frame(variable = v, categoria = rownames(t), n_normal = t[, "0"], n_ataque = t[, "1"],
    pct_ataque = 100 * t[, "1"] / rowSums(t))
}))
guardar(cruces, "cruces_categoricas")
print(cruces)

# 13. Observaciones influyentes: distancia de Cook > 4/n.
cook <- cooks.distance(modelo)
umbral_cook <- 4 / nrow(train)
influyentes <- data.frame(umbral = umbral_cook, n_influyentes = sum(cook > umbral_cook),
  pct = 100 * mean(cook > umbral_cook), cook_max = max(cook), id_cook_max = train$id[which.max(cook)],
  n_cook_mayor_1 = sum(cook > 1))
guardar(influyentes, "influyentes")
print(influyentes)

```

```r
# 14. Guardar el modelo y lo necesario para reproducir las predicciones.
# Interpretación: la probabilidad predicha es relativa a ESTA base (≈ 52 % de ataques,
# sin duplicados, ataques sintéticos del laboratorio): se interpretan los odds ratios,
# no prevalencias absolutas. El OR de PCk es por cada desvío del puntaje.
saveRDS(list(modelo = modelo, elegido = elegido, M1 = M1, M2 = M2, acp_entrenamiento = acp_tr,
  idx_train = idx_train, idx_test = idx_test, ids_train = base$id[idx_train],
  ids_test = base$id[idx_test], semilla = 42), "resultados/logistica.rds")
cat("Listo. Modelo", elegido, "| AUC prueba:", coma(as.numeric(auc(roc_te))),
  "IC95 [", coma(ic_auc[1]), ",", coma(ic_auc[3]), "]\n")
```

`R/ejecutar_todo.R` · Ejecución completa del proyecto

```r
# Ejecutar desde la carpeta principal del repositorio.
# Paquetes (una sola vez):
# install.packages(c("readxl", "psych", "GPArotation", "cluster", "ca", "FactoMineR",
#                    "MASS", "pROC", "writexl"))
# Las figuras se crean luego con Python; ver Como_ejecutar.txt.
for (archivo in c("00_datos.R", "01_acp.R", "02_af.R", "03_cluster.R", "04_acm.R",
                  "05_integracion.R", "06_logistica.R")) {
  cat("\nEJECUTANDO", archivo, "\n")
  source(paste0("R/", archivo), encoding = "UTF-8")
}
```

B.2. Scripts de Python

`python/graficos_etapa0.py` · Gráficos de la Etapa 0

```python
"""Gráficos pastel de la Etapa 0. Ejecutar después de R/00_datos.R."""
from pathlib import Path

import matplotlib
matplotlib.use("Agg")  # Exportación reproducible: no abre ventanas ni requiere pantalla.
import matplotlib.pyplot as plt
from matplotlib.colors import LinearSegmentedColormap
from matplotlib.ticker import MaxNLocator, FuncFormatter, ScalarFormatter
import numpy as np
import pandas as pd

ROOT = Path(__file__).resolve().parents[1]
TABLES = ROOT / "resultados" / "tablas"
FIGURES = ROOT / "resultados" / "figuras"
FIGURES.mkdir(parents=True, exist_ok=True)

def read(name):
    return pd.read_csv(TABLES / f"{name}.csv")

base = pd.read_excel(ROOT / "muestra_estratificada-simulado-de-ataques.xlsx", sheet_name="muestra")
diccionario = read("diccionario_variables")
conjuntos = read("conjuntos_congelados")
variables = conjuntos.loc[conjuntos.conjunto.eq("X_num"), "variable"].tolist()
crudas = [v.removeprefix("log_") for v in variables]
crudas.insert(2, "dpkts")  # Se describe la respuesta del destino, aunque no entra en X_num.
limites = read("atipicos_limites").set_index("variable")
frecuencias = read("frecuencias_X_cat")
correlaciones = read("correlaciones").set_index("variable")
msa = read("msa_por_variable")
piloto = read("piloto_supuestos").iloc[0]

plt.rcParams.update({"font.family": "DejaVu Sans", "font.size": 10,
    "axes.titlesize": 11, "axes.labelsize": 10, "figure.facecolor": "white",
    "axes.facecolor": "white", "axes.spines.top": False, "axes.spines.right": False,
    "text.color": "#283C49", "axes.labelcolor": "#283C49",
    "xtick.color": "#465761", "ytick.color": "#465761"})
PASTEL = ["#C7DCEB", "#D7CCE8", "#CDE2D3", "#F0D4BE", "#EBCDD5"]
EDGE = "#556874"

def coma_decimal(fig):
    """Usar coma decimal en los ejes numéricos, como en el resto del informe."""
    for ax in fig.axes:
```

```
        for eje in (ax.xaxis, ax.yaxis):
            if isinstance(eje.get_major_formatter(), ScalarFormatter):
                eje.set_major_formatter(FuncFormatter(lambda v, _: f"{v:g}".replace(".", ",")))

def guardar(fig, name):
    coma_decimal(fig)
    fig.savefig(FIGURES / f"{name}.png", dpi=200, bbox_inches="tight", facecolor="white")
    plt.close(fig)

def ejes_panel(cantidad=12):
    filas = (cantidad + 3) // 4
    return plt.subplots(filas, 4, figsize=(15, filas * 3.7), layout="constrained")

def nota(fig, texto):
    fig.supxlabel(texto, fontsize=9, color="#465761")

# Se usan las bisagras calculadas por R; bxp evita diferencias de cuartiles por empates.
fig, axes = ejes_panel()
for i, (ax, v) in enumerate(zip(axes.flat, variables)):
    row = limites.loc[v]
    x = base[v].to_numpy()
    extremos = x[(x < row.limite_inferior) | (x > row.limite_superior)]
    stats = {"med": row.mediana, "q1": row.q1_tukey, "q3": row.q3_tukey,
        "whislo": row.bigote_inferior, "whishi": row.bigote_superior, "fliers": extremos}
    ax.bxp([stats], positions=[1], widths=.45, patch_artist=True, manage_ticks=False,
        boxprops={"facecolor": PASTEL[i // 4], "edgecolor": EDGE},
        medianprops={"color": "#283C49", "linewidth": 1.5},
        whiskerprops={"color": EDGE}, capprops={"color": EDGE},
        flierprops={"marker": ".", "markersize": 3, "alpha": .28,
                    "markeredgecolor": EDGE, "markerfacecolor": EDGE})
    ax.set_title(f"{v}\n{int(row.n_atipicos):,} atípicos".replace(",", "."))
    ax.set_xticks([])
    ax.set_ylabel("log(x + 1)")
    ax.grid(axis="y", color="#E5E9EC", linewidth=.5)
fig.suptitle("Control de atípicos · 12 variables seleccionadas", fontsize=17)
nota(fig, "5.000 flujos · bisagras de Tukey ± 1,5 RIC · escalas independientes · se conservan todos los
    ↪ registros")
guardar(fig, "01_boxplots")

# Histogramas: todos los datos, sin recortar colas; bins FD con tope visual de 80.
def histogramas(lista, nombre, titulo, escala):
    fig, axes = ejes_panel(len(lista))
    for i, (ax, v) in enumerate(zip(axes.flat, lista)):
        x = base[v].to_numpy()
        q1, q3 = np.quantile(x, [.25, .75])
        ancho = 2 * (q3 - q1) / np.cbrt(len(x))
        n_bins = int(np.clip(np.ceil(np.ptp(x) / ancho), 10, 80)) if ancho > 0 else 20
        ax.hist(x, bins=n_bins, color=PASTEL[i // 4], edgecolor=EDGE, linewidth=.35)
        unidad = diccionario.set_index("nombre").loc[v, "unidad"]
        ax.set_title(v)
        ax.set_xlabel(unidad.replace(" (ventana", "\n(ventana"))
        ax.set_ylabel("Flujos")
        ax.xaxis.set_major_locator(MaxNLocator(nbins=4))
        ax.ticklabel_format(axis="x", style="sci", scilimits=(-3, 4), useMathText=True)
        ax.grid(axis="y", color="#E5E9EC", linewidth=.5)
    for ax in axes.flat[len(lista):]:
        ax.axis("off")
    fig.suptitle(titulo, fontsize=17)
    nota(fig, f"5.000 flujos · {escala} · rango completo, sin eliminar extremos · intervalos FD limitados a
    ↪ 10-80")
    guardar(fig, nombre)

histogramas(variables, "02_histogramas_log", "Distribuciones de X_num · escala log(x + 1)", "12 variables
    ↪ seleccionadas")
histogramas(crudas, "03_histogramas_crudos", "Distribuciones originales · comparación con la transformación
    ↪ ", "13 mediciones originales, incluido dpkts")

# Tamaño compacto: la figura va a media columna en el informe, así que la letra
# se dimensiona para que los valores se lean impresos (título y nota van en el epígrafe).
fig, ax = plt.subplots(figsize=(4.6, 4.0), layout="constrained")
cmap = LinearSegmentedColormap.from_list("pastel_divergente", ["#9CBAD4", "#FAFAF7", "#DFB0BC"])
im = ax.imshow(correlaciones.to_numpy(), vmin=-1, vmax=1, cmap=cmap)
labels = ["dur", "spkts", "sbytes", "dbytes", "sinpkt", "sjit", "synack",
```

```
          "srv_src", "srv_dst", "src_ltm", "src_dport", "dst_sport"]
labels = [dict(zip(["log_" + l for l in ["dur", "spkts", "sbytes", "dbytes", "sinpkt", "sjit", "synack",
          "ct_srv_src", "ct_srv_dst", "ct_src_ltm", "ct_src_dport_ltm", "ct_dst_sport_ltm"]], labels)).get(
    ↪ v, v)
          for v in variables]
ax.set_xticks(range(12), labels, rotation=55, ha="right", fontsize=8.5)
ax.set_yticks(range(12), labels, fontsize=8.5)
ax.spines[:].set_visible(False)
for i in range(12):
    for j in range(12):
        ax.text(j, i, f"{correlaciones.iloc[i, j]:.1f}".replace(".", ","), ha="center", va="center",
                fontsize=7.5, color="#283C49")
barra = fig.colorbar(im, ax=ax, shrink=.8)
barra.ax.tick_params(labelsize=8)
barra.set_label("r de Pearson", fontsize=8.5)
coma_decimal(fig)
guardar(fig, "04_correlaciones")

fig, axes = plt.subplots(2, 4, figsize=(17, 9), layout="constrained")
for i, (ax, v) in enumerate(zip(axes.flat, frecuencias.variable.unique())):
    f = frecuencias[frecuencias.variable.eq(v)].sort_values("frecuencia")
    # Mantener el orden natural de las bandas, aunque sus frecuencias sean similares.
    ordenes = {"duracion_banda": ["larga", "media", "corta"],
               "bytes_origen_banda": ["altos", "medios", "bajos"]}
    if v in ordenes:
        f = f.set_index("categoria").loc[ordenes[v]].reset_index()
    ax.barh(f.categoria, f.porcentaje, color=PASTEL[i % len(PASTEL)], edgecolor=EDGE, linewidth=.5)
    ax.set_xlim(0, 100)
    ax.set_xlabel("Porcentaje de flujos")
    ax.set_title(v)
    ax.grid(axis="x", color="#E5E9EC", linewidth=.5)
    for j, row in enumerate(f.itertuples()):
        ax.text(row.porcentaje + 1, j, f"{row.porcentaje:.1f}%".replace(".", ","), va="center", fontsize
    ↪ =9)
axes.flat[-1].axis("off")
fig.suptitle("Frecuencias de X_cat · propuesta operativa para ACM", fontsize=17)
nota(fig, "5.000 flujos · 4 categóricas existentes + 3 numéricas discretizadas · ninguna modalidad por
    ↪ debajo de 5 %")
guardar(fig, "05_frecuencias_categoricas")

fig, ax = plt.subplots(figsize=(10, 7), layout="constrained")
f = msa.sort_values("msa")
ax.barh(f.variable, f.msa, color=PASTEL[0], edgecolor=EDGE, linewidth=.5)
ax.axvline(.5, color="#7C5363", linestyle="--", linewidth=1.2, label="Umbral MSA = 0,50")
ax.set_xlim(0, 1)
for i, row in enumerate(f.itertuples()):
    ax.text(row.msa + .01, i, f"{row.msa:.3f}".replace(".", ","), va="center")
ax.set_xlabel("MSA por variable")
ax.set_title(f"Adecuación por variable · KMO global = {piloto.kmo_global:.3f}".replace(".", ","), fontsize
    ↪ =15)
ax.legend(loc="lower right")
guardar(fig, "06_msa")


print("Se guardaron las seis figuras en resultados/figuras.")
```

`python/graficos_parte2.py` · Gráficos de las Etapas 1 a 4

```
"""Figuras de todas las técnicas. Ejecutar después de R/ejecutar_todo.R."""
from pathlib import Path
import matplotlib
matplotlib.use("Agg")
import matplotlib.pyplot as plt
from matplotlib.colors import LinearSegmentedColormap
from matplotlib.ticker import MaxNLocator, FuncFormatter, ScalarFormatter
import numpy as np
import pandas as pd

ROOT = Path(__file__).resolve().parents[1]
T = ROOT / "resultados/tablas"
F = ROOT / "resultados/figuras"
```

```
F.mkdir(exist_ok=True)
def leer(n): return pd.read_csv(T / f"{n}.csv")
base = pd.read_excel(ROOT / "muestra_estratificada-simulado-de-ataques.xlsx", sheet_name="muestra")
vars_num = leer("conjuntos_congelados").query('conjunto == "X_num"').variable.tolist()
ABR = ["dur", "spkts", "sbytes", "dbytes", "sinpkt", "sjit", "synack", "srv_src", "srv_dst", "src_ltm", "
    ↪ src_dport", "dst_sport"]
COL = ["#B9D2E5", "#D1C3E0", "#BCD8C5", "#E6C4A7", "#E5BCC8", "#C7D8D4", "#D8D2B1"]
TRAFICO = dict(zip(["Normal", "Exploits", "Fuzzers", "Reconnaissance", "Otros ataques"], COL))
DARK = "#405361"
CMAP = LinearSegmentedColormap.from_list("suave", ["#94B7D2", "#FCFCF9", "#D9A7B5"])
plt.rcParams.update({"font.family": "DejaVu Sans", "font.size": 13,
    "axes.spines.top": False, "axes.spines.right": False, "axes.titlesize": 13,
    "text.color": DARK, "axes.labelcolor": DARK, "figure.facecolor": "white"})

def coma_decimal(fig):
    """Usar coma decimal en los ejes numéricos, como en el resto del informe."""
    for ax in fig.axes:
        for eje in (ax.xaxis, ax.yaxis):
            if isinstance(eje.get_major_formatter(), ScalarFormatter):
                eje.set_major_formatter(FuncFormatter(lambda v, _: f"{v:g}".replace(".", ",")))

def guardar(fig, nombre):
    coma_decimal(fig)
    fig.savefig(F / f"{nombre}.png", dpi=220, bbox_inches="tight", facecolor="white")
    plt.close(fig)

def origen(ax):
    ax.axhline(0, color="#D0D6DB", lw=.7)
    ax.axvline(0, color="#D0D6DB", lw=.7)

def adjust_text(texts, ax, expand=None, arrowprops=None):
    """Colocar etiquetas sin solaparlas, usando solo Matplotlib."""
    ax.set_autoscale_on(False)
    ax.figure.canvas.draw()
    renderer = ax.figure.canvas.get_renderer()
    inv = ax.transData.inverted()
    ocupados = []
    offsets = sorted([(dx,dy) for dx in [0,-20,20,-45,45,-80,80,-130,130,-180,180] for dy in range
    ↪ (-160,161,14)], key=lambda z:z[0]**2+z[1]**2)
    for text in sorted(texts, key=lambda t:t.get_position()[1]):
        original = text.get_position()
        origen = ax.transData.transform(original)
        mejor = None
        for dx,dy in [(0,0)]+offsets:
            text.set_position(inv.transform(origen + [dx,dy]))
            bb = text.get_window_extent(renderer).expanded(1.12,1.3)
            if bb.x0 < ax.bbox.x0 or bb.x1 > ax.bbox.x1 or bb.y0 < ax.bbox.y0 or bb.y1 > ax.bbox.y1:
    ↪ continue
            if any(bb.overlaps(o) for o in ocupados): continue
            mejor = bb; break
        if mejor is None:
            text.set_position(original)
            mejor = text.get_window_extent(renderer)
        ocupados.append(mejor)
        if np.linalg.norm(ax.transData.transform(text.get_position())-origen)>5:
            ax.plot([original[0],text.get_position()[0]],[original[1],text.get_position()[1]],color="#
    ↪ AAB2B9",linewidth=.45)

def dendrogram(link, ax, labels=None, truncate_mode=None, p=25, orientation="top", **kwargs):
    """Dibujar con Matplotlib el árbol Ward ya calculado en R, sin recalcularlo."""
    n = len(link) + 1
    limite = 2 * n - p if truncate_mode else n
    hojas = []
    def ordenar(node):
        if node < n or node < limite:
            hojas.append(node)
        else:
            ordenar(int(link[node - n, 0])); ordenar(int(link[node - n, 1]))
    ordenar(2 * n - 2)
    posiciones = {node: i for i, node in enumerate(hojas)}
    def trazar(node):
        if node in posiciones: return posiciones[node], 0
        row = link[node - n]
```

```
        a, ha = trazar(int(row[0])); b, hb = trazar(int(row[1]))
        xx, yy = [a, a, b, b], [ha, row[2], row[2], hb]
        if orientation == "right": ax.plot(yy, xx, color="#8EA9BE", lw=1)
        else: ax.plot(xx, yy, color="#8EA9BE", lw=1)
        return (a + b) / 2, row[2]
    trazar(2 * n - 2)
    nombres = [(labels[node] if labels else str(node + 1)) if node < n else f"({int(link[node - n, 3])})"
     ↪ for node in hojas]
    if orientation == "right": ax.set_yticks(range(len(hojas)), nombres, fontsize=12)
    else: ax.set_xticks(range(len(hojas)), nombres, fontsize=11)

# Resumen gráfico de datos para el informe; las figuras completas de Etapa 0 se conservan.
fig = plt.figure(figsize=(10, 4.2), layout="constrained")
rejilla = fig.add_gridspec(2, 4, width_ratios=[1, 1, 1.25, 1.25])
axs = np.array([[fig.add_subplot(rejilla[0, 0]), fig.add_subplot(rejilla[0, 1])],
    [fig.add_subplot(rejilla[1, :2]), fig.add_subplot(rejilla[:, 2:])]])
for ax, v, unidad in [(axs[0, 0], "dur", "segundos"), (axs[0, 1], "log_dur", "log(segundos + 1)")]:
    ax.hist(base[v], bins=40, color=COL[0], edgecolor=DARK, lw=.3)
    ax.set(title=v, xlabel=unidad, ylabel="Flujos")
lim = leer("atipicos_limites").set_index("variable")
seleccion = ["log_spkts", "log_sbytes", "log_dbytes"]
stats = []
for v in seleccion:
    r = lim.loc[v]; x = base[v]
    stats.append(dict(label=v.removeprefix("log_"), med=r.mediana, q1=r.q1_tukey,
        q3=r.q3_tukey, whislo=r.bigote_inferior, whishi=r.bigote_superior,
        fliers=x[(x < r.limite_inferior) | (x > r.limite_superior)].to_numpy()))
axs[1, 0].bxp(stats, patch_artist=True, boxprops=dict(facecolor=COL[1], edgecolor=DARK),
    medianprops=dict(color=DARK), flierprops=dict(marker=".", markersize=2, alpha=.2))
axs[1, 0].set(title="Atípicos de volumen", ylabel="log(x + 1)")
corr = leer("correlaciones").set_index("variable")
im = axs[1, 1].imshow(corr, cmap=CMAP, vmin=-1, vmax=1)
axs[1, 1].set_xticks(range(12), ABR, rotation=55, ha="right", fontsize=11)
axs[1, 1].set_yticks(range(12), ABR, fontsize=11)
axs[1, 1].set_title("Correlaciones (12 log_)")
fig.colorbar(im, ax=axs[1, 1], shrink=.7)
guardar(fig, "07_datos_resumen")

# ACP: el biplot usa escalas recíprocas, conservando el producto fila-columna.
eig = leer("acp_autovalores")
scores = leer("acp_puntajes")
r = leer("acp_correlaciones").set_index("variable")
fig, axs = plt.subplots(1, 2, figsize=(9, 3.6), layout="constrained", gridspec_kw={"width_ratios": [1,
     ↪ 1.6]})
axs[0].plot(eig.componente, eig.autovalor, "o-", color="#8AABC5", markeredgecolor=DARK)
axs[0].axhline(1, color=DARK, ls="--", lw=.8)
axs[0].set(title="Codo del ACP", xlabel="Componente", ylabel="Autovalor", xticks=range(1, 13))
ax = axs[1]
sx = np.sqrt(eig.autovalor.iloc[:2].to_numpy())
xy = .5 * scores[["PC1", "PC2"]].to_numpy() / sx
for cat, color in TRAFICO.items():
    sel = scores.tipo_trafico.eq(cat)
    ax.scatter(xy[sel, 0], xy[sel, 1], s=6, color=color, alpha=.4, label=cat, rasterized=True)
texts = []
ax.set_xlim(-2.35, 2.35)
ax.set_ylim(-1.5, 2.1)
for i, v in enumerate(vars_num):
    arrow = 2 * r.loc[v, ["PC1", "PC2"]].to_numpy()
    ax.annotate("", xy=arrow, xytext=(0, 0), arrowprops=dict(arrowstyle="->", color=DARK, lw=.8))
    texts.append(ax.text(arrow[0], arrow[1], ABR[i], fontsize=11))
ext = leer("acp_extremos")
for row in ext.itertuples():
    j = scores.index[scores.id.eq(row.id)][0]
    texts.append(ax.text(*xy[j], str(row.id), fontsize=11, fontweight="bold"))
origen(ax)
pct = eig.porcentaje.iloc[:2].round(2).map(lambda v: f"{v:.2f}".replace(".", ","))
ax.set(title="Biplot de individuos y variables", xlabel=f"CP1 ({pct.iloc[0]}%)", ylabel=f"CP2 ({pct.iloc
     ↪ [1]}%)")
fig.legend(*ax.get_legend_handles_labels(), fontsize=10, loc="outside lower center", ncol=5, markerscale=2)
adjust_text(texts, ax=ax, arrowprops=dict(arrowstyle="-", color="#929BA2", lw=.4))
guardar(fig, "08_acp_codo_biplot")

par = leer("af_paralelo")
```

```
fig, ax = plt.subplots(figsize=(9, 2.0), layout="constrained")
ax.plot(par.dimension, par.factor_observado, "o-", color="#8AABC5", label="Factores observados")
ax.plot(par.dimension, par.factor_simulado, "s--", color="#B7A4C9", label="Referencia aleatoria")
ax.axvline(3.5, color=DARK, ls=":", lw=1, label="Factores retenidos (3, Kaiser reducido)")
ax.axvline(4.5, color="#929BA2", ls="--", lw=.8, label="Corte del análisis paralelo (4)")
ax.set(xlabel="Número de factor", ylabel="Autovalor reducido", title="Análisis paralelo de factores · 100 repeticiones", xticks=range(1, 13))
ax.set_ylim(-0.8, 6.2)
ax.legend(fontsize=10, ncol=2, loc="upper right")
guardar(fig, "09_af_paralelo")

def linkage_r(nombre, n):
    d = leer(nombre); counts = np.zeros(n - 1); rows = []
    for i, row in enumerate(d.itertuples()):
        a = -int(row.izquierda) - 1 if row.izquierda < 0 else n + int(row.izquierda) - 1
        b = -int(row.derecha) - 1 if row.derecha < 0 else n + int(row.derecha) - 1
        count = (1 if a < n else counts[a - n]) + (1 if b < n else counts[b - n])
        counts[i] = count
        rows.append([a, b, row.altura, count])
    return np.array(rows)

metricas = leer("cluster_metricas")
k = int(leer("cluster_comparaciones").iloc[0].k)
fig, axs = plt.subplots(1, 2, figsize=(10, 2.8), layout="constrained")
for ax, pref, titulo, ylabel in [(axs[0], "wss", "Codo", "Suma de cuadrados interna"),
    (axs[1], "silhouette", "Silhouette promedio", "Silhouette")]:
    ax.plot(metricas.k, metricas[f"{pref}_ward"], "s--", color="#B7A4C9", label="Ward")
    ax.plot(metricas.k, metricas[f"{pref}_kmeans"], "o-", color="#8AABC5", label="K-means")
    ax.axvline(k, color=DARK, lw=.7, ls=":")
    ax.set(title=titulo, xlabel="k", ylabel=ylabel, xticks=range(2, 9))
    ax.legend(fontsize=12)
guardar(fig, "10_cluster_seleccion")

fig, ax = plt.subplots(figsize=(10, 2.6), layout="constrained")
link = linkage_r("cluster_dendrograma", len(base))
dendrogram(link, truncate_mode="lastp", p=15, ax=ax, link_color_func=lambda _: "#8EA9BE", leaf_font_size=8)
ax.axhline((link[-k, 2] + link[-k + 1, 2]) / 2, color=DARK, ls="--", lw=.8)
ax.set(title="Ward.D2 · últimos 15 nodos del árbol de 5.000 flujos", xlabel="Nodos agregados (tamaño entre paréntesis)", ylabel="Altura")
guardar(fig, "11_cluster_dendrograma")

fig, axs = plt.subplots(1, 2, figsize=(10, 3.8), layout="constrained", gridspec_kw={"width_ratios": [1.35, 1]})
perfil = leer("cluster_medias_estandarizadas").set_index("cluster")
im = axs[0].imshow(perfil, cmap=CMAP, vmin=-3, vmax=3, aspect="auto")
axs[0].set_xticks(range(12), ABR, rotation=55, ha="right", fontsize=11)
axs[0].set_yticks(range(k), [f"C{i}" for i in range(1, k + 1)])
axs[0].set_title("Medias z por cluster")
for i in range(k):
    for j in range(12): axs[0].text(j, i, f"{perfil.iloc[i,j]:.1f}".replace(".", ","), ha="center", va="center", fontsize=12)
fig.colorbar(im, ax=axs[0], shrink=.65, label="z (colores saturan en ±3)")
dendrogram(linkage_r("cluster_dendrograma_variables", 12), labels=ABR, orientation="right",
    ax=axs[1], link_color_func=lambda _: "#8EA9BE", leaf_font_size=9)
axs[1].set(title="Ward de variables", xlabel="Distancia")
guardar(fig, "12_cluster_perfiles_variables")

fig, ax = plt.subplots(figsize=(6.4, 2.6), layout="constrained")  # compacta: va a media página
texts = []
coords_acs = []
for name, color, marker in [("acs_filas", COL[0], "o"), ("acs_columnas", COL[4], "s")]:
    d = leer(name)
    coords_acs.append(d.iloc[:, 1:3].to_numpy())
    ax.scatter(d.iloc[:,1], d.iloc[:,2], color=color, edgecolor=DARK, s=50, marker=marker,
        label="Tipo de tráfico" if name.endswith("filas") else "Estado")
    # Con solo ocho puntos, cada etiqueta se ubica con un desplazamiento fijo
    # (en puntos) para que no tape su marcador ni a sus vecinas.
    lugar = {"Otros ataques": (0, 7, "center"), "INT": (0, -13, "center"),
             "Fuzzers": (0, 7, "center"), "Reconnaissance": (0, -13, "center"),
             "FIN": (8, 0, "left"), "Exploits": (8, 0, "left"),
             "Normal": (8, 0, "left"), "CON_otros": (0, -13, "center")}
    for _, row in d.iterrows():
        dx, dy, ha = lugar.get(row.iloc[0], (6, 6, "left"))
```

```
        ax.annotate(row.iloc[0], (row.iloc[1], row.iloc[2]), xytext=(dx, dy),
                    textcoords="offset points", ha=ha, va="center", fontsize=11)
coords_acs = np.vstack(coords_acs)
ax.set_xlim(coords_acs[:, 0].min() - .25, coords_acs[:, 0].max() + .25)
ax.set_ylim(coords_acs[:, 1].min() - .2, coords_acs[:, 1].max() + .2)
origen(ax)
ax.set(xlabel="Dimensión 1", ylabel="Dimensión 2", title="ACS · tipo de tráfico y estado")
ax.legend(fontsize=10, loc="upper center", bbox_to_anchor=(0.42, 1), ncol=2)
guardar(fig, "13_acs_mapa")

e = leer("acm_autovalores")
fig, axs = plt.subplots(1, 2, figsize=(10, 2.1), layout="constrained")
axs[0].plot(e.dimension, e.autovalor, "o-", color="#8AABC5")
axs[0].axhline(1/leer("acm_resumen").Q.iloc[0], color=DARK, ls="--", lw=.8)
axs[0].set(title="Autovalores crudos del ACM", xlabel="Dimensión", ylabel="Autovalor")
axs[0].xaxis.set_major_locator(MaxNLocator(integer=True))
axs[1].bar(e.dimension.iloc[:6], e.porcentaje_ajustado.iloc[:6], color=COL[1], edgecolor=DARK, linewidth
    ↪ =.5)
axs[1].set(title="Inercia ajustada (ca::mjca)", xlabel="Dimensión", ylabel="Porcentaje ajustado")
guardar(fig, "14_acm_inercia")

co = leer("acm_categorias_coordenadas")
variables_cat = co.categoria.str.split(":").str[0].unique().tolist()
prefijos = dict(zip(variables_cat, ["Tr", "Pr", "Sv", "Es", "Rp", "Du", "By"]))
marcas = ["o", "s", "^", "D", "v", "P", "X"]
fig, ax = plt.subplots(figsize=(9, 4.9), layout="constrained")
texts = []
for i, var in enumerate(variables_cat):
    d = co[co.categoria.str.startswith(var + ":")]
    ax.scatter(d["Dim.1"], d["Dim.2"], color=COL[i], edgecolor=DARK, linewidth=.6,
        marker=marcas[i], s=45, label=f"{prefijos[var]}: {var}")
    for row in d.itertuples(index=False, name=None):
        lab = row[0].split(":", 1)[1].replace("Otros ataques", "Otros at.").replace("Reconnaissance", "
    ↪ Recon.")
        texts.append(ax.text(row[1], row[2], prefijos[var] + ":" + lab, fontsize=12))
ax.margins(.22)
origen(ax)
ax.set(title="ACM · categorías activas", xlabel="Dimensión 1 · 27,42% cruda", ylabel="Dimensión 2 · 14,03%
    ↪ cruda")
fig.supxlabel("Tr tráfico · Pr protocolo · Sv servicio · Es estado · Rp respuesta · Du duración · By bytes",
    ↪ fontsize=10)
adjust_text(texts, ax=ax, expand=(1.1, 1.2), arrowprops=dict(arrowstyle="-", color="#AAB2B9", lw=.5))
guardar(fig, "15_acm_categorias")

fig, axs = plt.subplots(1, 2, figsize=(10, 3.5), layout="constrained")
ind = leer("acm_individuos")
su = leer("acm_cluster_suplementario")
for i in range(1, k + 1):
    d = ind[ind.cluster.eq(i)]
    axs[0].scatter(d["Dim.1"], d["Dim.2"], s=5, alpha=.15, color=COL[i - 1], rasterized=True)
    r = su[su.cluster.eq(i)].iloc[0]
    axs[0].scatter(r["Dim.1"], r["Dim.2"], color=COL[i - 1], edgecolor=DARK, marker="D", s=65)
    axs[0].annotate(f"C{i}", (r["Dim.1"], r["Dim.2"]), xytext=(5, 4), textcoords="offset points", fontsize
    ↪ =12)
origen(axs[0])
axs[0].set(title="Clusters suplementarios", xlabel="Dimensión 1", ylabel="Dimensión 2")
eta = leer("acm_eta2")
y = np.arange(len(eta))
axs[1].barh(y - .18, eta["Dim.1"], height=.35, color=COL[0], edgecolor=DARK, lw=.4, label="Dim 1")
axs[1].barh(y + .18, eta["Dim.2"], height=.35, color=COL[1], edgecolor=DARK, lw=.4, label="Dim 2")
axs[1].set_yticks(y, eta.variable, fontsize=12)
axs[1].set(xlim=(0, 1), xlabel="eta²", title="Discriminación por variable")
axs[1].legend(fontsize=12)
guardar(fig, "16_acm_clusters_eta")
print("Figuras 07 a 16 generadas con Matplotlib.")
```

`python/graficos_logistica.py` · Gráficos de la regresión logística

```
"""Figuras 17 y 18 de la regresión logística. Ejecutar después de R/06_logistica.R."""
from pathlib import Path
import matplotlib
```

```
matplotlib.use("Agg")
import matplotlib.pyplot as plt
from matplotlib.colors import LinearSegmentedColormap
from matplotlib.ticker import FuncFormatter, ScalarFormatter
import numpy as np
import pandas as pd

ROOT = Path(__file__).resolve().parents[1]
T = ROOT / "resultados/tablas"
F = ROOT / "resultados/figuras"
F.mkdir(exist_ok=True)
def leer(n): return pd.read_csv(T / f"log_reg_{n}.csv")

# Mismo estilo que graficos_parte2.py
COL = ["#B9D2E5", "#D1C3E0", "#BCD8C5", "#E6C4A7", "#E5BCC8", "#C7D8D4", "#D8D2B1"]
DARK = "#405361"
CMAP = LinearSegmentedColormap.from_list("suave", ["#FCFCF9", "#94B7D2"])
plt.rcParams.update({"font.family": "DejaVu Sans", "font.size": 13,
    "axes.spines.top": False, "axes.spines.right": False, "axes.titlesize": 13,
    "text.color": DARK, "axes.labelcolor": DARK, "figure.facecolor": "white"})

def coma_decimal(fig):
    """Usar coma decimal en los ejes numéricos, como en el resto del informe."""
    for ax in fig.axes:
        for eje in (ax.xaxis, ax.yaxis):
            if isinstance(eje.get_major_formatter(), ScalarFormatter):
                eje.set_major_formatter(FuncFormatter(lambda v, _: f"{v:g}".replace(".", ",")))

def guardar(fig, nombre):
    coma_decimal(fig)
    fig.savefig(F / f"{nombre}.png", dpi=220, bbox_inches="tight", facecolor="white")
    plt.close(fig)

roc = leer("roc_curva")
auc = leer("auc").iloc[0]
conf = leer("confusion")
met = leer("metricas").iloc[0]

# Figura 17: ROC en prueba + matriz de confusión (umbral 0,5)
fig, axs = plt.subplots(1, 2, figsize=(10, 4.2), layout="constrained")
ax = axs[0]
ax.plot([0, 1], [0, 1], ls="--", color="#AAB2B9", lw=1, label="Azar (AUC = 0,500)")
ax.plot(roc.fpr, roc.tpr, color="#6F9BBC", lw=2.2,
        label=f"Modelo (AUC = {auc.AUC:.3f})".replace(".", ","))
ax.fill_between(roc.fpr, roc.tpr, alpha=.15, color=COL[0])
punto = (1 - met.especificidad, met.sensibilidad)
ax.scatter(*punto, s=55, color="#D9A7B5", edgecolor=DARK, zorder=3, label="Umbral 0,5")
ax.set(xlabel="1 - especificidad (falsos positivos)", ylabel="Sensibilidad (verdaderos positivos)",
       xlim=(0, 1), ylim=(0, 1.01), aspect="equal")
ax.legend(loc="lower right", fontsize=11, frameon=False)

ax = axs[1]
m = np.array([[conf.query('real=="normal" and predicho=="normal"').n.iloc[0],
               conf.query('real=="normal" and predicho=="ataque"').n.iloc[0]],
              [conf.query('real=="ataque" and predicho=="normal"').n.iloc[0],
               conf.query('real=="ataque" and predicho=="ataque"').n.iloc[0]]])
pct = m / m.sum(axis=1, keepdims=True)
ax.imshow(pct, cmap=CMAP, vmin=0, vmax=1)
for i in range(2):
    for j in range(2):
        ax.text(j, i, f"{m[i, j]}\n({100 * pct[i, j]:.1f}%)".replace(".", ","), ha="center", va="center",
                fontsize=14, color=DARK, fontweight="bold" if i == j else "normal")
ax.set_xticks([0, 1], ["Normal", "Ataque"])
ax.set_yticks([0, 1], ["Normal", "Ataque"])
ax.set(xlabel="Clase predicha", ylabel="Clase real")
for s in ax.spines.values():
    s.set_visible(False)
ax.tick_params(length=0)
guardar(fig, "17_logistica_roc_confusion")

# Figura 18: forest plot de OR (escala log) + calibración por deciles
co = leer("coeficientes").set_index("termino")
orx = leer("or_por_desvio").set_index("termino")
```

```python
nombres = {"PC1": "PC1 (por desvío)", "PC2": "PC2 (por desvío)", "PC3": "PC3 (por desvío)",
           "proto_gudp": "Protocolo: udp (vs tcp)", "proto_gotros": "Protocolo: otros (vs tcp)",
           "service_gdns": "Servicio: dns (vs ninguno)", "service_ghttp": "Servicio: http (vs ninguno)",
           "service_gotros": "Servicio: otros (vs ninguno)",
           "state_gCON_otros": "Estado: CON_otros (vs FIN)", "state_gINT": "Estado: INT (vs FIN)"}
filas = []
for t in nombres:
    if t not in co.index: continue
    if t in orx.index:
        r = orx.loc[t]; filas.append((nombres[t], r.OR_por_desvio, r.OR_desvio_IC95_inf, r.
    ↪ OR_desvio_IC95_sup, t))
    else:
        r = co.loc[t]; filas.append((nombres[t], r.OR, r.OR_IC95_inf, r.OR_IC95_sup, t))
filas = filas[::-1]
fig, axs = plt.subplots(1, 2, figsize=(10.5, 4.6), layout="constrained", gridspec_kw={"width_ratios":
    ↪ [1.25, 1]})
ax = axs[0]
y = np.arange(len(filas))
for i, (n, o, lo, hi, t) in enumerate(filas):
    color = "#6F9BBC" if t.startswith("PC") else "#C9899B"
    ax.plot([lo, hi], [i, i], color=color, lw=2)
    ax.scatter(o, i, color=color, edgecolor=DARK, s=40, zorder=3)
ax.axvline(1, color=DARK, lw=.9, ls="--")
ax.set_xscale("log")
ax.set_xticks([.05, .2, 1, 5, 20, 100, 400], ["0,05", "0,2", "1", "5", "20", "100", "400"])
ax.minorticks_off()
ax.set_yticks(y, [f[0] for f in filas], fontsize=11)
ax.set(xlabel="Odds ratio e IC 95 % (escala log)")

ax = axs[1]
cal = leer("calibracion")
ax.plot([0, 1], [0, 1], ls="--", color="#AAB2B9", lw=1, label="Calibración perfecta")
ax.plot(cal.p_media, cal.prop_observada, "o-", color="#6F9BBC", markeredgecolor=DARK, label="Deciles en
    ↪ prueba")
ax.set(xlabel="Probabilidad media predicha", ylabel="Proporción observada de ataques",
       xlim=(0, 1), ylim=(0, 1.02), aspect="equal")
ax.legend(loc="upper left", fontsize=11, frameon=False)
guardar(fig, "18_logistica_or_calibracion")
print("Figuras 17 y 18 generadas con Matplotlib.")
```

`python/verificar_resultados.py` · Verificación independiente de resultados

```python
"""Comprobación independiente de los resultados de R con NumPy y pandas."""
from pathlib import Path
import numpy as np
import pandas as pd

ROOT = Path(__file__).resolve().parents[1]
T = ROOT / "resultados/tablas"
def leer(n): return pd.read_csv(T / f"{n}.csv")
base = pd.read_excel(ROOT / "muestra_estratificada-simulado-de-ataques.xlsx", sheet_name="muestra")
assert base.shape == (5000, 68)
variables = leer("conjuntos_congelados").query('conjunto == "X_num"').variable.tolist()
x = base[variables].to_numpy()
z = (x - x.mean(axis=0)) / x.std(axis=0, ddof=1)
R = np.corrcoef(x, rowvar=False)
eig = np.linalg.eigvalsh(R)[::-1]
np.testing.assert_allclose(eig, leer("acp_autovalores").autovalor, atol=1e-12)
np.testing.assert_allclose(R, leer("correlaciones").iloc[:, 1:], atol=1e-12)
inversa = np.linalg.inv(R)
anti = inversa / np.sqrt(np.outer(inversa.diagonal(), inversa.diagonal()))
r2 = R**2; q2 = anti**2
np.fill_diagonal(r2, 0); np.fill_diagonal(q2, 0)
np.testing.assert_allclose(r2.sum() / (r2.sum() + q2.sum()), leer("piloto_supuestos").kmo_global.iloc[0])

asignaciones = leer("cluster_asignaciones")
np.testing.assert_array_equal(asignaciones.id, base.id)
wss = 0
for g in sorted(asignaciones.cluster.unique()):
    grupo = z[asignaciones.cluster.eq(g)]
    wss += ((grupo - grupo.mean(axis=0))**2).sum()
```

```
np.testing.assert_allclose(wss, leer("cluster_metricas").query('k == 6').wss_kmeans.iloc[0])
assert leer("cluster_tamanos").n.sum() == 5000
af = leer("af_cargas_completas")
# El AF final es GLS con 3 factores y se calcula por optimización: se admite su tolerancia numérica.
np.testing.assert_allclose((af[["F1", "F2", "F3"]]**2).sum(axis=1), af.comunalidad, atol=1e-4)
assert (af.unicidad > .005).all()  # la solución final no es un caso Heywood
assert (af[["F1", "F2", "F3"]].abs() >= .4).sum(axis=1).ge(1).all()
diag = leer("af_diagnostico_minres").set_index("metodo")
assert diag.loc["minres", "heywood"]  # el caso Heywood de minres se documenta, no se oculta
assert not diag.loc["gls", "heywood"]
# Las cargas deben reproducir la matriz de correlaciones con el RMSR informado.
L = af[["F1", "F2", "F3"]].to_numpy()
resid = R - L @ L.T
rmsr = np.sqrt(np.mean(resid[np.tril_indices(12, -1)]**2))
np.testing.assert_allclose(rmsr, leer("af_ajuste").rmsr.iloc[0], atol=1e-4)

# Rehacer el ACM indicador y el ajuste de Greenacre sin FactoMineR ni ca.
q = base[["tipo_trafico", "proto_g", "service_g", "state_g"]].copy()
q["respuesta_destino"] = np.where(base.dpkts.eq(0), "sin_respuesta", "con_respuesta")
c = leer("cortes_discretizacion").set_index("variable")
q["duracion_banda"] = pd.cut(base.dur, [-np.inf, c.loc["dur", "corte_1"], c.loc["dur", "corte_2"], np.inf],
    ↪  labels=["corta", "media", "larga"])
q["bytes_origen_banda"] = pd.cut(base.sbytes, [-np.inf, c.loc["sbytes", "corte_1"], c.loc["sbytes", "
    ↪ corte_2"], np.inf], labels=["bajos", "medios", "altos"])
A = pd.get_dummies(q, dtype=float).to_numpy()
n, Q, J = len(q), len(q.columns), A.shape[1]
P = A / (n * Q)
cm = P.sum(axis=0)
S = (P - cm / n) / np.sqrt(cm / n)
lamb = np.linalg.svd(S, compute_uv=False)[:J - Q]**2
acm = leer("acm_autovalores")
np.testing.assert_allclose(lamb, acm.autovalor, atol=1e-11)
ajustados = np.where(lamb > 1 / Q, (Q / (Q - 1) * (lamb - 1 / Q))**2, 0)
total = Q / (Q - 1) * (np.sum(lamb**2) - (J - Q) / Q**2)
np.testing.assert_allclose(ajustados, acm.autovalor_ajustado, atol=1e-11)
np.testing.assert_allclose(100 * ajustados / total, acm.porcentaje_ajustado, atol=1e-10)
t = leer("acs_contingencia").iloc[:, 1:].to_numpy()
esperados = np.outer(t.sum(axis=1), t.sum(axis=0)) / t.sum()
np.testing.assert_allclose(((t - esperados)**2 / esperados).sum(), leer("acs_asociacion").chi2.iloc[0])
assert (leer("frecuencias_X_cat").groupby("variable").frecuencia.sum() == 5000).all()
print("Verificación correcta: ACP, KMO, WSS, AF, ACS y ACM con ajuste de inercia.")
```